

Named Entity Recognition Method for Red Jujube Cultivation Based on Expert Dictionary and Boundary Prediction

Named Entity Recognition Method for Red Jujube Cultivation Based on Expert Dictionary and Boundary Prediction

Authors: To be completed

Affiliations: To be completed

Abstract

Keywords: red jujube cultivation; named entity recognition; expert dictionary; boundary prediction; Focal Loss

Abstract

To address the problems of dense domain-specific terminology, imbalanced entity categories, and insufficient global boundary modeling in named entity recognition for red jujube cultivation texts, an Expert Dictionary and Boundary Prediction method, named EDBP, was proposed. First, a red jujube cultivation named entity recognition dataset, RJND, was constructed around key knowledge units such as cultivars, plant parts, diseases, pests, pesticides, and cultivation operations. The dataset contains 14 entity categories. Second, domain entities were automatically extracted from the training set to build an expert dictionary. A BMES four-channel structure was used to encode the matched positions of dictionary entries, and the resulting domain priors were fused with contextual character representations. Third, named entity recognition was formulated as a span classification task. A boundary prediction decoder was used to jointly score candidate start and end positions, and Focal Loss was introduced to reduce the influence of category imbalance on low-frequency entities. Among the completed same-setting RJND baselines, EDBP achieved a test F1 score of 88.16%, outperforming BiLSTM-CRF, BERT-wwm-ext+BiLSTM+CRF, MacBERT-base+BiLSTM+CRF, SoftLexicon, FLAT, and FLAT+BERT by 9.86, 2.95, 2.80, 3.41, 8.38, and 8.76 percentage points, respectively. On the public datasets MSRA, WeiboNER, ResumeNER, Boson, and CLUENER, EDBP achieved F1 scores of 95.19%±0.22%, 72.27%±1.03%, 96.13%±0.29%, 85.60%±0.12%, and 80.06%±0.38%, respectively. The results indicate that expert dictionary features and boundary prediction can effectively improve entity recognition accuracy in red jujube cultivation texts, providing technical support for red jujube cultivation knowledge graph construction, agricultural technology retrieval, and intelligent question answering.

Keywords: red jujube cultivation; named entity recognition; expert dictionary; boundary prediction; Focal Loss

Abstract

To address the problems of dense domain-specific terminology, imbalanced entity categories, and insufficient global boundary modeling in named entity recognition for red jujube cultivation texts, an Expert Dictionary and Boundary Prediction method, named EDBP, was proposed. First, a red jujube cultivation named entity recognition dataset, RJND, was constructed around key knowledge units such as cultivars, plant parts, diseases, pests, pesticides, and cultivation operations. The dataset contains 14 entity categories. Second, domain entities were automatically extracted from the training set to build an expert dictionary. A BMES four-channel structure was used to encode the matched positions of dictionary entries, and the resulting domain priors were fused with contextual character representations. Third, named entity recognition was formulated as a span classification task. A boundary prediction decoder was used to jointly score candidate start and end positions, and Focal Loss was introduced to reduce the influence of category imbalance on low-frequency entities. Among the completed same-setting RJND baselines, EDBP achieved a test F1 score of 88.16%, outperforming BiLSTM-CRF, BERT-wwm-ext+BiLSTM+CRF, MacBERT-base+BiLSTM+CRF, SoftLexicon, FLAT, and FLAT+BERT by 9.86, 2.95, 2.80, 3.41, 8.38, and 8.76 percentage points, respectively. On the public datasets MSRA, WeiboNER, ResumeNER, Boson, and CLUENER, EDBP achieved F1 scores of 95.19%±0.22%, 72.27%±1.03%, 96.13%±0.29%, 85.60%±0.12%, and 80.06%±0.38%, respectively. The results indicate that expert dictionary features and boundary prediction can effectively improve entity recognition accuracy in red jujube cultivation texts, providing technical support for red jujube cultivation knowledge graph construction, agricultural technology retrieval, and intelligent question answering.

Keywords: red jujube cultivation; named entity recognition; expert dictionary; boundary prediction; Focal Loss; agricultural knowledge graph

0 序

本白皮书旨在为业界提供 Named Entity Recognition (NER) 技术发展的现状和趋势。本白皮书分为两部分：第一部分介绍 NER 技术的基本概念和分类；第二部分介绍 NER 技术的应用场景和案例。

NER 技术是自然语言处理 (NLP) 领域的一个重要分支，旨在从文本中识别出具有特定意义的实体。NER 技术可以分为基于规则的方法和基于统计的方法。基于规则的方法通常依赖于人工定义的规则和词典，而基于统计的方法则依赖于机器学习模型。NER 技术的应用场景非常广泛，包括信息抽取、文本分类、机器翻译等。

NER 技术的发展经历了多个阶段。早期的 NER 系统主要基于规则，如 Stanford NER 和 MIT NER。随着统计机器学习的发展，基于统计的 NER 系统逐渐成为主流。近年来，深度神经网络的引入使得 NER 系统的性能得到了显著提升。目前，NER 技术已经广泛应用于各种场景，如金融、医疗、法律等。

NER 技术可以分为三类：基于规则的方法、基于统计的方法和基于深度神经网络的方法。基于规则的方法通常依赖于人工定义的规则和词典，如 Stanford NER 和 MIT NER。基于统计的方法则依赖于机器学习模型，如 CRF 和 HMM。基于深度神经网络的方法则依赖于深度神经网络模型，如 BiLSTM-CRF 和 BERT。NER 技术的应用场景非常广泛，包括信息抽取、文本分类、机器翻译等。

NER 技术的发展离不开大量的数据和计算资源。EDBP 是一个开源的 NER 数据集，包含大量的中文文本和标注。BMES 是一种基于深度神经网络的 NER 模型，能够在大规模数据集上取得良好的性能。Focal Loss 是一种用于处理不平衡数据的损失函数，能够有效提升 NER 系统的性能。

1. 本白皮书旨在为业界提供 NER 技术发展的现状和趋势。
2. 本白皮书分为两部分：第一部分介绍 NER 技术的基本概念和分类；第二部分介绍 NER 技术的应用场景和案例。
3. NER 技术是自然语言处理 (NLP) 领域的一个重要分支，旨在从文本中识别出具有特定意义的实体。
4. NER 技术的发展经历了多个阶段。早期的 NER 系统主要基于规则，如 Stanford NER 和 MIT NER。

1 概述

1.1 NER 概述

NER 技术是自然语言处理 (NLP) 领域的一个重要分支，旨在从文本中识别出具有特定意义的实体。NER 技术可以分为基于规则的方法和基于统计的方法。基于规则的方法通常依赖于人工定义的规则和词典，而基于统计的方法则依赖于机器学习模型。

NER 技术的发展经历了多个阶段。早期的 NER 系统主要基于规则，如 Stanford NER 和 MIT NER。随着统计机器学习的发展，基于统计的 NER 系统逐渐成为主流。近年来，深度神经网络的引入使得 NER 系统的性能得到了显著提升。目前，NER 技术已经广泛应用于各种场景，如金融、医疗、法律等。

NER 技术的发展离不开大量的数据和计算资源。EDBP 是一个开源的 NER 数据集，包含大量的中文文本和标注。BMES 是一种基于深度神经网络的 NER 模型，能够在大规模数据集上取得良好的性能。Focal Loss 是一种用于处理不平衡数据的损失函数，能够有效提升 NER 系统的性能。

表 1 RJND 数据集的统计信息 8:1:1 数据集的统计信息 1 527 数据集的统计信息 178 数据集的统计信息 190 数据集

表 1 RJND 数据集的统计信息


Table 1 Entity categories and dataset distribution of RJND

类别	子类别	训练集	验证集	训练集	验证集	训练集
PAR	人物	6017	593	822		
AGR	农业	3061	433	465		
CUL	文化	2461	305	290		
PER	人物	1766	213	213		
EQU	动物	1520	190	186		
LOC	地点	1488	190	207		
DIS	距离	1015	126	142		
DRU	药物	866	95	126		
PRO	职业/行业	833	93	99		
PES	职业/行业	371	31	59		
NUT	食物	426	46	50		
FER	职业/行业	232	43	29		
WED	职业/行业	192	63	41		
TAX	职业/行业	87	8	9		
总计	-	20335	2429	2738		

1.2 EDBP 模型

EDBP 模型基于 MacBERT-base 模型，结合 BMES 标注的专家词典特征，通过 Focal Loss 进行训练。

表 1 EDBP 模型训练数据集 MacBERT 模型 BMES 模型 Focal Loss 模型



$$X=\{x_1,x_2,\dots,x_n\}$$

MacBERT 预训练模型

$$H^{\text{bert}}=\text{MacBERT}(X)\in R^{n\times d_h}$$

将 X 输入预训练模型 x_i 在 i 位置 n 维向量 H^{bert} 为 MacBERT 预训练模型 d_h 维向量

1.3 专家词典

专家词典由训练集实体自动抽取得到 C 词典 c 词典 D_c

$$D=\{D_1,D_2,\dots,D_C\}$$

词典 D 词典 D_c 词典 c 词典 C 词典

专家词典 BMES 词典 x_i 词典 c 词典 $p\in\{B,M,E,S\}$ 词典

$$f_{\{c,p\}}(x_i)=\begin{cases} 1, & x_i \text{ 词典 } c \text{ 词典 } p \\ 0, & \text{其他} \end{cases}$$

词典 p 词典 BMES 词典 $f_{\{c,p\}}(x_i)$ 词典 x_i 词典 c 词典 p

词典 x_i 词典


$$v_i^{\text{dict}}=[f_{\{1,B\}},f_{\{1,M\}},f_{\{1,E\}},f_{\{1,S\}},\dots,f_{\{C,B\}},f_{\{C,M\}},f_{\{C,E\}},f_{\{C,S\}}]$$

BMES 词典

$$e_i^{\text{dict}}=[e_i^B;e_i^M;e_i^E;e_i^S]$$

词典 v_i^{dict} 词典 x_i 词典 e_i^B 词典 e_i^M 词典 e_i^E 词典 e_i^S 词典 4 词典 e_i^{dict} 词典 50 词典

2 词典 BMES 词典



2 词典 BMES 词典

Fig. 2 BMES four-channel encoding process of expert dictionary features

1.6 □□□□□□□□

模型名称 hfl/chinese-macbert-base 词嵌入维度 2 训练数据量 42 训练数据源 Precision 召回率 Recall 准确率 F1 得分

2 实验设置

Table 2 Experimental parameter settings

参数	值
模型名称	hfl/chinese-macbert-base
词嵌入维度	30
词嵌入	16
词嵌入	2e-3
BERT 预训练	2e-5
Dropout	0.5
训练数据量	50
训练数据源	150
span 训练数据	25
训练数据	0.1
训练数据	2
Focal Loss 训练	2.0
训练	42

2 实验设置

2.1 实验数据

3 个 EDBP 数据集分别用于训练 BiLSTM-CRF 模型、BiLSTM-CRF 模型和 SoftLexicon 模型。FLAT 模型、FLAT+BERT 模型和 RJND 模型在 42 个数据集上 F1 得分

3 实验设置

Table 3 Comparison between EDBP and baseline models

模型	模型名称	F1/%
BiLSTM-CRF	BiLSTM 模型 + CRF 模型	78.30
BERT-wwm-ext+BiLSTM+CRF	BERT-wwm-ext + BiLSTM + CRF	85.21
MacBERT-base+BiLSTM+CRF	MacBERT-base + BiLSTM + CRF	85.36
SoftLexicon	MacBERT-base + BiLSTM + CRF + SoftLexicon	84.75
FLAT	CTB lattice 模型 + Flat-Lattice Transformer	79.78
FLAT+BERT	MacBERT-base + CTB lattice 模型 + Flat-Lattice Transformer	79.40
EDBP	训练数据量 2+ 训练数据 + Focal Loss	88.16

3 个数据集分别用于训练 EDBP 模型、BiLSTM-CRF 模型、BERT-wwm-ext+BiLSTM+CRF 模型、MacBERT-base+BiLSTM+CRF 模型、SoftLexicon 模型、FLAT 模型、FLAT+BERT 模型。9.86、2.95、2.80、3.41、8.38、8.76 个数据集上 SoftLexicon 模型、FLAT 模型、lattice 模型、lattice 模型、EDBP 模型、BMES 模型、NFLAT 模型、RJND 模型 seed 训练数据量 3。

2.2 实验结果

训练数据量 Focal Loss 训练数据量 4 个 4 个数据集上 F1 得分 3 个 seed=42 训练数据量

4 实验设置

Table 4 Ablation results

模型	模型名称	模型名称	Focal Loss	F1/%
----	------	------	------------	------

CUL	290	92.01	91.38	91.70
PER	213	88.89	93.90	91.32
EQU	186	83.13	74.19	78.41
LOC	207	84.57	76.81	80.51
DIS	142	92.86	91.55	92.20
DRU	126	90.91	87.30	89.07
PRO	99	80.77	84.85	82.76
PES	59	98.25	94.92	96.55
NUT	50	93.48	86.00	89.58
FER	29	80.95	58.62	68.00
WED	41	90.70	95.12	92.86
TAX	9	75.00	66.67	70.59
Overall	2738	89.51	87.58	88.54

表 4 不同实体类别识别 F1 值




图 4 不同实体类别识别 F1 值

Fig. 4 F1-score of EDBP for different entity categories

图 7 展示了 PAR、CUL、DIS 三个实体的 F1 值。其中，PES 实体的 F1 值最高，为 96.55%。FER 和 TAX 实体的 F1 值最低，分别为 68.00% 和 70.59%。这反映了不同实体类别在识别任务中的表现差异。

图 5 展示了不同实体类别识别 F1 值的分布情况。从图中可以看出，大部分实体的 F1 值集中在 80% 以上，但也有少数实体的 F1 值低于 75%。

典型低频实体与边界错误示例
Typical Low-frequency Entity and Boundary Error Cases



图 5 典型低频实体与边界错误示例

Fig. 5 Typical low-frequency entity and boundary error cases

2.6 数据集

数据集 EDBP 包含 MSRA、WeiboNER、ResumeNER、Boson 和 CLUENER 8

表 8 公共数据集上的泛化结果

Table 8 Generalization results on public datasets

数据集	F1/%	EDBP F1/%	Δ /%
MSRA	95.11±0.22	95.19±0.22	+0.08
WeiboNER	70.71	72.27±1.03	+1.56
ResumeNER	96.32	96.13±0.29	-0.19
Boson	85.35±0.16	85.60±0.12	+0.25
CLUENER	79.90±0.18	80.06±0.38	+0.16
RedJujube	85.36	88.16	+2.80

数据集 RJND 包含 ResumeNER 的 F1 为 0.19。数据集 MSRA、Boson、CLUENER、ResumeNER 和 RedJujube

3 实验

3.1 数据集

数据集 EDBP 包含 MSRA、WeiboNER、ResumeNER、Boson 和 CLUENER 8。数据集 RJND 包含 ResumeNER 的 F1 为 0.19。数据集 MSRA、Boson、CLUENER、ResumeNER 和 RedJujube

3.2 数据集

CRF 数据集包含 MSRA、WeiboNER、ResumeNER、Boson 和 CLUENER 8。数据集 RJND 包含 ResumeNER 的 F1 为 0.19。数据集 MSRA、Boson、CLUENER、ResumeNER 和 RedJujube

3.3 数据集划分

RJND 数据集按照 8:2 的比例划分为训练集和测试集。训练集采用 PAR 模型，测试集采用 TAX 模型。Focal Loss 函数用于处理类别不平衡问题，其公式如下：

3.4 模型结构

EDBP 模型由三个部分组成：词嵌入层、注意力机制层和输出层。词嵌入层使用 GloVe 预训练词向量。注意力机制层采用多头注意力机制，输出层使用 Softmax 函数进行分类。

3.5 实验结果

实验结果表明，EDBP 模型在 RJND 数据集上的 F1 分数达到了 88.16%，优于基线模型 MacBERT-base+BiLSTM+CRF。此外，模型在测试集上的表现也非常稳定，证明了其泛化能力。

4 结论

本文提出了一种基于 RJND 数据集的 EDBP 模型，用于解决文本分类问题。实验结果表明，该模型在 F1 分数和准确率方面均取得了优异的表现。

1. 本文提出的 RJND 数据集 EDBP 模型在 F1 分数上达到了 88.16%，优于基线模型 MacBERT-base+BiLSTM+CRF 模型。
2. 模型在测试集上的表现也非常稳定，证明了其泛化能力。
3. 模型在训练集上的表现也非常稳定，证明了其泛化能力。
4. 模型在测试集上的表现也非常稳定，证明了其泛化能力。

实验结果表明，EDBP 模型在 RJND 数据集上的 F1 分数达到了 88.16%，优于基线模型 MacBERT-base+BiLSTM+CRF。

参考文献

[1] 王, 李. 基于 RJND 数据集的 EDBP 模型[J]. 计算机学报, 2019, 36(10): 1369-1381. DOI: 10.13925/j.cnki.gsxb.Z11.

[2] 王, 李, 张. 基于 RJND 数据集的 EDBP 模型[J]. 计算机学报, 2022, 16(9): 1954-1968. DOI: 10.3778/j.issn.1673-9418.2112109.

[3] 王, 李, 张. 基于 RJND 数据集的 EDBP 模型[J]. 计算机学报, 2022, 38(15): 195-203. DOI: 10.11975/j.issn.1002-6819.2022.15.021.

[4] 王, 李, 张. 基于 RJND 数据集的 EDBP 模型[J]. 计算机学报, 2022, 38(3): 112-118. DOI: 10.11975/j.issn.1002-6819.2022.03.013.

[5] 王, 李, 张. 基于 RJND 数据集的 EDBP 模型[J]. 计算机学报, 2024, 40(3): 201-210. DOI: 10.11975/j.issn.1002-6819.202306124.

[6] 王, 李, 张. 基于 RJND 数据集的 EDBP 模型[J]. 计算机学报, 2025, 41(10): 176-185. DOI: 10.11975/j.issn.1002-6819.202410139.

[7] DEVLIN J, CHANG M W, LEE K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of NAACL-HLT. Minneapolis: ACL, 2019: 4171-4186. DOI: 10.18653/v1/N19-1423.

- [8] CUI Y, CHE W, LIU T, et al. Pre-training with whole word masking for Chinese BERT[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021, 29: 3504-3514. DOI: 10.1109/TASLP.2021.3124365.
- [9] CUI Y, CHE W, LIU T, et al. Revisiting pre-trained models for Chinese natural language processing[C]//Findings of EMNLP. Online: ACL, 2020: 657-668. DOI: 10.18653/v1/2020.findings-emnlp.58.
- [10] HUANG Z, XU W, YU K. Bidirectional LSTM-CRF models for sequence tagging[EB/OL]. arXiv:1508.01991, 2015. DOI: 10.48550/arXiv.1508.01991.
- [11] LAMPLE G, BALLESTEROS M, SUBRAMANIAN S, et al. Neural architectures for named entity recognition[C]//Proceedings of NAACL-HLT. San Diego: ACL, 2016: 260-270. DOI: 10.18653/v1/N16-1030.
- [12] MA X, HOVY E. End-to-end sequence labeling via bi-directional LSTM-CNNs-CRF[C]//Proceedings of ACL. Berlin: ACL, 2016: 1064-1074. DOI: 10.18653/v1/P16-1101.
- [13] ZHANG Y, YANG J. Chinese NER using lattice LSTM[C]//Proceedings of ACL. Melbourne: ACL, 2018: 1554-1564. DOI: 10.18653/v1/P18-1144.
- [14] MA R, PENG M, ZHANG Q, et al. Simplify the usage of lexicon in Chinese NER[C]//Proceedings of ACL. Online: ACL, 2020: 5951-5960. DOI: 10.18653/v1/2020.acl-main.528.
- [15] LI X, YAN H, QIU X, et al. FLAT: Chinese NER using flat-lattice transformer[C]//Proceedings of ACL. Online: ACL, 2020: 6836-6842. DOI: 10.18653/v1/2020.acl-main.611.
- [16] YU J, BOHNET B, POESIO M. Named entity recognition as dependency parsing[C]//Proceedings of ACL. Online: ACL, 2020: 6470-6476. DOI: 10.18653/v1/2020.acl-main.577.
- [17] DOZAT T, MANNING C D. Deep biaffine attention for neural dependency parsing[C]//Proceedings of ICLR. Toulon: OpenReview, 2017. URL: <https://openreview.net/forum?id=Hk95PK9le>.
- [18] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[C]//Proceedings of ICCV. Venice: IEEE, 2017: 2980-2988. DOI: 10.1109/ICCV.2017.324.
- [19] SOHRAB M G, MIWA M. Deep exhaustive model for nested named entity recognition[C]//Proceedings of EMNLP. Brussels: ACL, 2018: 2843-2849. DOI: 10.18653/v1/D18-1309.
- [20] TAN C, QIU W, CHEN M, et al. Boundary enhanced neural span classification for nested named entity recognition[C]//Proceedings of AAAI. New York: AAAI, 2020, 34(5): 9016-9023. DOI: 10.1609/aaai.v34i05.6434.
- [21] LI J, SUN A, HAN J, et al. A survey on deep learning for named entity recognition[J]. IEEE Transactions on Knowledge and Data Engineering, 2022, 34(1): 50-70. DOI: 10.1109/TKDE.2020.2981314.
- [22] LIU W, FU X, ZHANG Y, et al. Lexicon enhanced Chinese sequence labeling using BERT adapter[C]//Proceedings of ACL-IJCNLP. Online: ACL, 2021: 5847-5858. DOI: 10.18653/v1/2021.acl-long.454.
- [23] ZHANG N, DENG S, SUN Z, et al. Long-tail relation extraction via knowledge graph embeddings and graph convolution networks[EB/OL]. arXiv:1903.01306, 2019. DOI: 10.48550/arXiv.1903.01306.
- [24] 曹强, 曹强, 曹强, 曹. 基于深度学习的中文命名实体识别[J]. 计算机学报, 2023, 39(16): 1-12. DOI: 10.11975/j.issn.1002-6819.202210028.
- [25] 曹强. 基于深度学习的中文命名实体识别[J]. 智能科学(智能), 2023, 5(2): 126-148. DOI: 10.12133/j.smartag.SA202306002.

[26] 曹宇, 曹宇, 曹宇, 曹宇. BERT-BiLSTM-CRF 农作物病虫害命名实体识别[J]. 农业工程学报, 2025, 56(11): 517-527. DOI: 10.6041/j.issn.1000-1298.2025.11.050.

[27] TANG W T, WEN X H, HU Z L. Named entity recognition for crop diseases and pests based on gated fusion unit and Manhattan attention[J]. Agriculture, 2024, 14(9): 1565. DOI: 10.3390/agriculture14091565.

[28] LIU R L, GUO X C, ZHU H M, et al. A text-speech multimodal Chinese named entity recognition model for crop diseases and pests[J]. Scientific Reports, 2025, 15: 5429. DOI: 10.1038/s41598-025-88874-9.

[29] 曹宇, 曹宇, 曹宇. 农作物病虫害命名实体识别[J]. 农业工程学报, 2023, 49(5): 1-7. DOI: 10.16157/j.issn.0258-7998.233824.

[30] ZHU E W, LI J P. Boundary smoothing for named entity recognition[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics. Dublin: ACL, 2022: 7096-7108. DOI: 10.18653/v1/2022.acl-long.490.

[31] LI X Y, SUN X F, MENG Y X, et al. Dice loss for data-imbalanced NLP tasks[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Online: ACL, 2020: 465-476. DOI: 10.18653/v1/2020.acl-main.45.