


学号：XXXXXX



长春理工大学

Changchun University of Science and Technology

硕士学位论文（毕业）论文

基于可解释图神经网络的中药方剂功用分类 研究

研 究 生：

类别领域：

指导教师：

二〇二六年六月

分类号: TP391

U D C:

密 级: 可公开

编 号:

基于可解释图神经网络的中药方剂功用分类研究

学位授予单位及代码: 长春理工大学 (10186)

类别领域名称及代码: 计算机技术 (085404)

研究方向: 机器学习

申请学位级别: 硕 士

研究生姓名: XXXXX

指导教师姓名: XXX

论文起止时间: 2024 年 6 月 — 2026 年 3 月

**Research on Classification of
Traditional Chinese Medicine Formula
Functions Based on Explainable Graph
Neural Networks**

by

XXX

Dissertation submitted to

Changchun University of Science and Technology

in partial fulfillment of the requirement

for the degree of

Master of Engineering

Supervisor

Professor XXX

June, 2026

长春理工大学硕士学位论文原创性声明

本人郑重声明：所呈交的硕士学位论文《基于可解释图神经网络的中药方剂功用分类研究》是本人在指导教师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

作者签名： 年 月 日

长春理工大学学位论文版权使用授权书

本学位论文作者及指导教师完全了解“长春理工大学硕士、博士学位论文版权使用规定”，即：研究生在校攻读学位期间论文工作的知识产权单位属长春理工大学。本人保证毕业离校后，发表论文或使用论文工作成果时署单位名称仍然为长春理工大学。同意长春理工大学保存并使用学位论文；同意长春理工大学向国家图书馆、中国学术期刊（光盘版）电子杂志社、中国科学信息研究所送交学位论文的复印件和电子版，允许论文被查阅和借阅。（涉密论文在解密后遵守此规定）

论文涉密情况约定：（打“√”选择）

☒ 本论文非涉密论文。

☐ 本论文属于涉密论文，在年解密后使用本授权书。

作者签名： 年 月 日

导师签名： 年 月

摘要

近年来,为促进中医药标准化,国家标准 GB/T31773—2015《中药方剂编码规则及编码》按照功用将方剂分为 20 个大类。然而,目前的方剂功用分类主要采用人工标注的方式,因此,该国标仅包含了 1089 首经典名方,对剩余海量方剂进行功用分类面临着高成本等诸多挑战,所以,实现中药方剂的自动分类具有较高的研究价值。在医药等科学领域,由于知识图谱能够有效地表示链接数据,图神经网络成为了相关领域的主要技术之一。然而,现有的图神经网络模型难以表示中药知识图谱中的君臣配伍等属性,较难区分方剂药味成分的主次关系,从而影响分类的准确性。此外,图神经网络具有“黑盒”特性,其决策过程缺乏透明性,难以解释方剂的组成成分等属性信息对其功用分类的影响。针对上述问题,主要研究内容如下:

(1) 依据国标数据集构建了中药方剂分类知识图谱。为了利用图神经网络实现中药方剂的自动分类,需要将以文本存储的原始国标数据结构化,并以图结构形式存储,但对于不同的构图方式,图神经网络表示学习的能力不同,会影响模型分类的准确性。本文首先利用中药方剂成分的相似性构建了中药方剂知识图谱。然而,由于该图谱缺少方剂间成分的主次关系信息,导致图神经网络模型对方剂药味成分的重要性关注不足。为此,本文进一步提出了基于配伍理论的中药方剂知识图谱构建方法,并融入“君臣佐使”等先验知识作为图的初始结构。

(2) 构建了 TCM-GAT,一种基于图神经网络的可解释中药方剂功用分类预测方法。首先,针对相似性知识图谱构建了 TCM-GCN,但 TCM-GCN 仅适用于该图谱,难以动态学习基于配伍理论的知识图谱中君臣配伍关系。为此,本文构建了 TCM-GAT,TCM-GAT 的训练过程融合了每首方剂中饮片的君臣配伍关系,因此该模型在方剂类别归属预测时能区分饮片成分的主次角色,从而提升模型预测的准确性。实验结果表明,TCM-GAT 在仅有少量标记样本时也能提升分类准确率。本文还将图神经网络的后验(post-hoc)解释方法引入到基于中药知识图谱的模型预测任务,以解析方剂的组成成分如何影响其功用分类,并对 TCM-GAT 的可解释性进行了抽样验证,结果显示本文方法能准确衡量方剂的饮片成分与和其功用之间的关联性。

关键词: 图神经网络; 可解释模型; 知识图谱; 功用分类; 中药方剂

ABSTRACT

In recent years, to promote the standardization of traditional Chinese medicine (TCM), the national standard GB/T 31773—2015 Coding Rules and Codes for Traditional Chinese Medicine Prescriptions classifies prescriptions into 20 major categories according to their therapeutic functions. However, the current classification of prescription functions mainly relies on manual annotation. As a result, the national standard includes only 1,089 classical prescriptions, and extending functional classification to a large number of remaining prescriptions faces challenges such as high labor cost and low scalability. Therefore, automatic classification of TCM prescriptions is of significant research value. In scientific domains such as medicine, knowledge graphs have been widely used to effectively represent linked data, making graph neural networks (GNNs) one of the dominant techniques in this field. However, existing GNN models struggle to represent specific properties of TCM knowledge graphs, such as the hierarchical compatibility relationships among herbal components (e.g., the Jun - Chen - Zuo - Shi principle). Consequently, these models have difficulty distinguishing the relative importance of herbal ingredients within a prescription, which negatively affects classification performance. Moreover, GNNs are often regarded as “black-box” models, whose decision-making processes lack transparency, making it difficult to explain how prescription components influence functional classification outcomes. To address these challenges, this thesis conducts the following research:

(1) Construction of a TCM prescription classification knowledge graph based on national standard data. To enable automatic classification of TCM prescriptions using GNNs, the original national standard data stored in textual form were first structured and represented as graphs. Since different graph construction strategies lead to different representation learning capabilities and thus affect classification accuracy, this study initially constructed a TCM prescription knowledge graph based on ingredient similarity. However, due to the lack of information on the hierarchical importance of prescription components, this graph limited the model's ability to capture the significance of individual herbal ingredients. To overcome this limitation, a knowledge graph construction method based on TCM compatibility theory was further proposed, incorporating prior knowledge such as the Jun - Chen - Zuo - Shi roles as the initial graph structure.

(2) Development of TCM-GAT, an interpretable graph neural network for TCM prescription functional classification. First, a TCM-GCN model was constructed based on the similarity-based knowledge graph. However, TCM-GCN is only applicable to this specific graph structure and cannot dynamically learn the compatibility relationships encoded in the theory-based knowledge graph. To this end, TCM-GAT was proposed. During training, TCM-GAT integrates the Jun - Chen compatibility relationships of herbal components within each prescription, enabling the model to distinguish the primary and secondary roles of ingredients when predicting prescription categories, thereby improving classification accuracy. Experimental results demonstrate that TCM-GAT achieves superior performance even with a limited number of labeled samples. Furthermore, post-hoc interpretability methods for graph neural networks were introduced into the TCM knowledge graph - based prediction task to analyze how prescription components influence functional classification. Sampling-based validation experiments confirm that the proposed method can accurately quantify the associations between herbal components and prescription functions.

Keywords: Graph Neural Networks; Interpretable Models; Knowledge Graphs; Functional Classification; Traditional Chinese Medicine Prescriptions

目 录

摘 要	I
ABSTRACT	II
目 录	IV
第 1 章 绪论	1
1.1 研究背景及意义	1
1.2 国内外研究现状	2
1.2.1 中医证候与疾病预测	2
1.2.2 可解释图神经网络	4
1.3 论文的主要研究内容和组织架构	6
1.3.1 论文研究内容	6
1.3.2 论文组织架构	7
第 2 章 相关理论基础与技术	9
2.1 中医药理论基础	9
2.1.1 中药方剂功用分类方法	9
2.1.2 中药方剂配伍理论	10
2.2 图神经网络及其可解释性	11
2.2.1 图卷积网络	11
2.2.2 可解释图神经网络	18
2.3 本章小结	23
第 3 章 TCM-GCN：基于成分相似性的中药方剂功用分类	24
3.1 引言	24
3.2 基于成分相似性的中药知识图谱	24
3.3 TCM-GCN 模型构建	27
3.3.1 特征矩阵的构建	27
3.3.2 分类器的设计	28
3.4 实验设置与结果分析	29
3.4.1 参数设置	29

3.4.2	评估指标	30
3.4.3	对比实验	31
3.4.4	结果分析	32
3.5	本章小结	34
第 4 章	TCM-GAT: 基于配伍理论的中药方剂功用分类	35
4.1	引言	35
4.2	基于配伍理论的中药知识图谱	35
4.3	TCM-GAT 模型构建	37
4.3.1	模型整体架构	37
4.3.2	融合多头注意力机制的图注意力层	38
4.4	TCM-GAT 实验设置与结果分析	42
4.4.1	参数设置	42
4.4.2	评估指标	43
4.4.3	对比与消融实验	44
4.4.4	结果分析	48
4.5	TCM-GAT 可解释性验证与实验分析	48
4.5.1	模型的后验解释	48
4.5.2	实验环境与参数配置	49
4.5.3	评估指标	50
4.5.4	对比实验	51
4.6	结果分析	54
4.7	本章小结	57
第 5 章	总结与展望	58
5.1	全文研究工作总结	58
5.2	未来研究工作展望	59
参考文献		60
附录	攻读硕士学位期间取得的成果	65
致谢		66

第1章 绪论

1.1 研究背景及意义

中药方剂作为中医“理法方药”核心要素之一，不仅理论内涵深厚，更贯穿了整个中医诊断的发展史^[1]，其分类体系历经千年演变：从《黄帝内经》、《伤寒杂病论》的病名和证候分类，发展为现代功用分类法。《伤寒论》等权威性的中医古籍成为了当代的医疗诊断和学术研究的基础，这些典籍记载了海量的中药方剂，但未建立系统的方剂分类体系。以《中医方剂大辞典》为例，书籍中收集了 10 万余首方剂，但却缺乏统一的分类标准。在此背景下，国家标准 GB/T31773—2015《中药方剂编码规则及编码》等相关文献，提出了以中药方剂的功能属性为基准的分类及编码标准。然而，目前的方剂功用分类主要采用人工标注的方式，因此，该国标仅包含了 1089 首经典名方，对剩余海量方剂进行功用分类面临着高成本等诸多挑战，所以，实现中药方剂的自动分类具有较高的研究价值。一方面，自动化分类方法能够有效降低人工标注成本，提高方剂功用分类的效率；另一方面，通过引入智能手段，有助于从海量中医方剂数据中挖掘潜在特征，从而提升分类的准确性，并为中医临床决策提供有效支撑。

人工智能和大数据技术的广泛应用为中药方剂分类研究提供了新的思路和方法。例如，图神经网络（Graph Neural Network, GNN）^[2]在复杂网络分析领域展现出了卓越的性能，并在药物研发^[3]、生物信息学^[4]等多个关键领域成效显著。作为一种深度学习模型，图神经网络擅长处理复杂的图结构数据，能够在图结构上对数据进行有效的特征提取和表示，该模型通过节点间的信息传递与聚合机制来捕捉网络中的复杂关系。因此，图神经网络在众多分类预测任务中表现优异。在中医药领域，由于知识图谱在结构化表示和建模复杂实体关系方面具有优势，知识图谱为中医药知识的挖掘与推理提供了基础，图神经网络也成为了相关领域的主要技术之一。然而，现有的图神经网络模型难以表示中药知识图谱中的君臣配伍等属性，较难区分方剂药味成分的主次关系，导致在方剂功用分类等任务中，模型对关键药物成分的识别能力受限，从而影响分类性能。在这一背景下，结合中医理论与图结构建模方法来设计图神经网络模型变得尤为重要。为此，本文构建了 TCM-GAT，该模型的训练过程融合了每首方剂中饮片的君臣配伍关系，从而更加精准的预测中药方剂的功用分类。

此外，多数 GNN 模型在做决策时缺乏解释机制，表现为“黑盒”模型，这种缺乏解释性的现象削弱了 GNN 预测结果的可靠性，导致研究人员难以深入理解模

型为何会做出特定的决策，也限制了其在关键决策场景中的应用。在这一背景下，可解释图神经网络应运而生，该方法通常基于合作博弈论等理论，量化预测结果的重要性，提供更直观的模型解释，从而帮助研究者理解预测模型的推理依据和决策过程。因此，将可解释图神经网络方法引入到中药方剂分类的任务中，可以量化方剂的药味组成在该任务中的重要性。本文提出的可解释图神经网络模型 TCM-GAT，不仅融合了中药知识图谱以及君臣配伍等多种类型的中药属性，还能解析中药成分与方剂功用之间的相互联系。本文的研究对中医药临床应用现代化具有以下指导价值：（1）通过分析药味组成贡献度，揭示药味组成成分对类别的影响机制；（2）通过解析成分作用机制提升用药透明度与可信度；（3）参考模型分析结果调整药方配比，以提升药效或降低某些药物成分潜在的副作用。因此，本文基于国标数据集提出的图神经网络模型 TCM-GAT 对中药方剂的功用分类预测具有重要意义。

1.2 国内外研究现状

1.2.1 中医证候与疾病预测

中医经过数千年的发展与完善，形成了一套以中药方剂为核心的知识理论体系，这一古老的知识体系为现代疾病预防和新药研发提供了思路。《伤寒论》等权威性的中医古书籍，成为了当代的医疗诊断和学术研究的基础，这些典籍记载了海量的中药方剂。然而，受限于历史条件与编纂方式，这些典籍未建立系统的方剂分类体系，导致方剂知识难以被高效整合与深度应用，这也为中医药的智能化研究带来了挑战。以《中医方剂大辞典》为例，书籍中收录了 10 万余首方剂，但缺乏统一的分类标准，这种分类体系的缺失制约了其在疾病预测等方面的智能化应用。近年来，随着中医药信息化进程的推进，各类中医药数据库相继建立。例如，中国方剂数据库^[5]汇集了 710 余种古籍和 84464 首方剂，构建了较为完整的方剂数据资源。数据库的建设为中医药知识的数字化存储提供了重要支撑。

人工智能技术的兴起为中医药信息的挖掘提供了技术支持，研究者们逐渐将多种算法模型应用到中医药领域，以研究疾病的根源、疾病的预测以及证候的分类等。陈昭等人^[6]验证了最小二乘-支持向量机（LS-SVM）分类模型在基于药性理论的清热药功效分类任务中的可行性，郭永坤等人^[7]利用神经网络构建了中药方剂功效预测模型，但二者的研究均存在样本数量少或类型单一的局限性。Gao 等人^[8]构建了传统中医向量化模型（TCM2Vec）；Bai 等人^[9]针对中医实体分类任务设计了基于卷积神经网络的分段注意机制模型；金博文等人^[10]基于 Preferential Attachment-

VIKOR 算法实现了对阿尔茨海默病中药处方与证候对应关系的预测。近年来,研究者们还采用多种方法对症状、中药及其复杂关系进行建模与分析。其中,主题模型与图神经网络是该领域中被广泛研究的代表性方法^[11-12]。在主题模型方面, Yao 等人^[13]运用主题建模方法深入探讨了中医处方的生成过程,挖掘出症状与中药之间的潜在模式与关联; Wang 等人^[14]在主题模型中引入了融合知识图谱的增强机制,通过引入知识图谱丰富了症状与中药之间的关系,这考虑了中医病例中的共现信息和症状与中药之间的语义关联。在图神经网络方面, Jin 等人^[15]基于处方中的共现频率构建了症状-症状图、中药-中药图以及症状-中药二部图,并采用图卷积网络(Graph Convolutional Network, GCN)^[16]建模症状与中药之间的潜在关系; Zhao 等人^[17]提出了一种基于多图卷积网络的处方推荐模型,通过构建症状-状态要素-症状图与症状-证型-症状图,建模症状与处方之间的关系; Yang 等人^[18]提出了一种融合多层信息的图卷积模型,并将其用于知识驱动的中草药推荐任务。尽管上述研究在中医领域取得了进步,推动了中医药领域的智能化发展,但现有模型普遍缺乏可解释性,这在一定程度上制约了中医智能化发展的深入推进。在中医领域,模型的可解释性不仅关乎算法结果的可信度,更直接影响到对方剂功效的理解与应用。

方剂的功效与其药味之间关系复杂,为方剂的临床应用带来了挑战,海量的方剂数据也给人工划分类别带来了困难。目前,很多国内学者对中药方剂分类进行了深入的研究。黄辛迪等人^[19]基于词向量和神经网络对方剂分类进行研究;刘丽蓉等人^[20]基于 BP 神经网络和 SVM 构建了荨麻疹证候分类模型;阮开霞等人^[21]基于多种机器学习和反向传播神经网络(BPNN)构建了中医补益类方剂分类模型; Kang 等人^[22]提出了一种基于深度学习的新方法,用于实现中草药的自动化分类。在国外,中药方剂分类的研究起步较晚,但近年来也取得了显著进展。Kanawong 等人^[23]提出了一种自动化舌象特征提取方法,用于中医证状分类; Kanawong 等人^[24]提出了一种改进的去镜面反射舌象图像处理方法,以提升中医“证”型分类的准确性; Moorhouse 等人^[25]提出了一种与生物多样性保护相关的中药分类体系。

知识图谱的概念由谷歌在 2012 年首次提出,其目的是通过增强搜索引擎的语义理解能力以提升搜索结果质量^[26],目前主要应用于智能搜索、个性化推荐等领域,如 YAGO^[27]、WordNet^[28]等知识图谱已应用于知识驱动任务中,并发挥了重要的作用。近年来,构建中医领域的知识图谱已成为推动中医知识标准化的重要方式,这也使研究数量庞大且复杂的中医药知识变得切实可行。在知识图谱的构建过程中,命名实体识别(NER)是关键的任务之一,研究者们常利用 BiLSTM-CRF^[29]等序列标注模型来完成实体识别,并结合不同的数据集和研究目标,开展了不同的研究。例如,卢克治^[30]对中医古籍进行研究,采用 BERT+BiLSTM+CRF 模型进行实体关

系抽取,从而构建结构化知识图谱;杜伯涵^[31]对中医门诊病例数据进行研究,通过结构化的方式将其表示为知识图谱中的实体和关系,并利用神经网络实现实体识别;刘禹琪^[32]对中药方剂进行研究,构建了中医名方知识图谱以完成链接预测。目前,中国中医科学院中医药信息研究所^[33]已构建了多类型的中医学知识图谱,这是该领域最具代表性的成果之一。当前中医知识图谱的研究主要集中于从多源异构数据中进行知识的抽取与整合,以构建静态的实体关系网络,然而,知识图谱的动态更新对中医药等科学领域也至关重要。

1.2.2 可解释图神经网络

图神经网络首次由 Scarselli 等人^[2]提出,其衍生模型有图注意力网络、图卷积网络、图自编码器 (Graph Autoencoder, GAE)^[34]等。图神经网络能够有效捕捉节点之间的结构依赖关系与节点特征,并通过邻居聚合机制实现节点表示的更新与传播。目前, GNN 已广泛应用于科学领域,凭借其在图结构数据建模与特征学习方面的优势,在交通预测^[35]、生物学^[36]和化学分子建模^[37]等任务中展现良好性能。图神经网络的兴起改变了图挖掘领域,使其从传统的特征工程迈入自动化表示学习的新阶段。GNN 已在多种图结构应用任务中展现出显著优势,尤其在半监督节点分类^[16]、推荐系统^[38]以及知识图谱推理^[39]等任务中取得了良好效果。为进一步提升 GNN 模型对复杂图结构的表达能力,研究者们相继提出了多种图操作方法,例如,图消息传递机制^[40]通过在节点间迭代聚合邻居信息,实现了对局部结构与上下文语义的有效建模;三维图操作^[41]扩展了传统二维图的建模范式,使模型能够处理具有空间拓扑特征的数据。此外,还通过引入注意力机制和图池化等技术,提升了 GNN 的表达能力。

GCN 在 2016 年由 Kipf 等人^[16]首次提出,作为一种基于谱域方法的图神经网络模型, GCN 通过对图拉普拉斯矩阵进行局部一阶近似,实现了高效的图卷积操作,该方法在保持模型表达能力的同时,显著降低了计算复杂度。国外学者在理论基础、模型扩展等方面对 GCN 开展了大量研究。在理论基础方面, Hamilton 等人^[42]提出 GraphSAGE, GraphSAGE 的原理是在 GCN 中引入采样机制,从而提升模型在大规模图数据上的可扩展性与计算效率。Velickovic 等人^[43]提出 GAT, GAT 的原理是在 GCN 中融入注意力机制,实现了对邻居节点信息的加权聚合。APPNP 等人^[44]通过引入基于个性化 PageRank 的传播机制进一步优化了信息传播方式,实现了多阶邻居信息聚合,该方法缓解了信息传播过程中的过平滑现象。在模型扩展方面, Xu 等人^[45]从图神经网络的图同构判别能力出发,提出了图同构网络 (Graph

Isomorphism Network, GIN), 并分析了 GCN 模型的局限性。近年来, 国内学者也将 GCN 用于众多领域, 并在中医药等领域展现出显著成效。例如, Teng 等人^[46]提出了基于 GCN 的中医证候分类方法, 通过构建中药方剂与证候之间的图结构关系, 实现了对中医证候的自动化识别与分类; Wang 等人^[47]提出了双部图聚类图卷积网络模型 (DTI-BGCGCN), 并将该模型用于中医药领域中的药物-靶点相互作用 (DTI) 预测。目前, 以 GCN 为基础的方法在节点分类、链接预测、图分类等任务上取得了已知的最优性能。

GAT 在 2017 年由 Petar Veličković 等人^[43]首次提出, 图注意力网络将图卷积与注意力机制结合, 摒弃了传统图神经网络中的拉普拉斯矩阵, 通过引入注意力权重分配策略, 实现对邻居节点的加权聚合, 从而优化节点表示的表达能力。针对 GAT 在大规模图上计算复杂度高问题, 研究者们提出了 Cluster-GAT^[48]、FastGAT^[49]等轻量化变体, 这些变体通过引入邻居采样机制与稀疏注意力计算等策略, 有效提升了训练效率。在医学领域, GAT 被广泛应用于构建医疗诊疗知识库。例如, 研究者用 GAT 分析不同等级疾病的共同特征, 还通过分析医疗发票等数据, 推断出患者可能罹患的疾病^[50]。在药物分类领域, Xiong 等人^[51]提出了一种基于 GAT 的分子表示方法, 以提升分子性质预测 (MPP) 的准确性; Yuan 等人^[52]将 GAT 用于药物-靶点相互作用 (DTI) 预测。除此外, Yang 等人^[53]提出了一种名为多图残差注意力网络和语义知识融合 (SMRGAT) 的草药推荐模型, 该模型考虑了症状的语义信息和不同药物对症状的治疗强度, 有效提升了草药推荐的准确性。Wang 等人^[54]提出了多任务元注意力网络 (Meta-Attention Network), 该模型是一种融合知识匹配机制的深度学习模型, 用于对医疗数据进行分析 and 预测。

GNN 模型通常由多层网络结构堆叠而成, 每两层网络之间会加入非线性激活函数, 从而增强模型的表达能力。尽管 GNN 具备强大的建模能力, 但其 “黑盒” 特性会导致决策逻辑不透明, 难以解释模型的决策依据, 可解释性的缺失也限制了 GNN 在医药等可解释性要求较高的场景下的应用。因此, 提升 GNN 的可解释性成为当前图学习领域的重要研究方向。在此背景下, 可解释图神经网络应运而生, 可解释图神经网络旨在提升模型透明度, 其研究始于 2015 年 Duvenaud 等人^[55]对分子指纹的图卷积解释。目前, 研究者提出多种可解释图神经网络方法, 例如, Ying 等人^[56]提出 GNNExplainer, 将其用于解释 GNN 在基因调控网络中的预测结果, 并识别出关键的调控因子子图; Luo 等人^[57]提出 PGExplainer, Rao 等人^[58]将其用于分子性质预测任务, 以识别关键的分子子结构; Gui 等人^[59]提出 FlowX, 并用其对分子图分类任务进行解释, 识别对预测结果影响最大的原子与键路径。近年来, 基于 Shapley 值的, 模型无关的可解释性方法, 如 SHAP (SHapley Additive

exPlanations) 等被提出。基于 Shapley 值的可解释图神经网络方法包括, GraphSVX^[60], GraphSHAP^[61], GStarX^[62]等。在医学领域,可解释图神经网络可以被用于阐释癌症基因的预测机制^[63],研究者已用 GNNExplainer 揭示了癌症基因预测过程中的关键特性,从而深化了对癌症发生与发展机制的理解。

1.3 论文的主要研究内容和组织架构

1.3.1 论文研究内容

本文主要的研究内容是基于可解释图神经网络方法对中药方剂进行功用分类和解释。首先,基于国标的数据集构建中药方剂知识图谱,然后,为了更精准地对中药方剂进行分类,构建了基于图注意力网络的 TCM-GAT,最后,基于训练好的 TCM-GAT,利用后验可解释图神经网络实现了药味成分对中药方剂分类贡献的量化。本论文的具体研究内容如下:

(1) 研究了基于国标数据集的知识图谱的构建方法。首先,本文采用了基本的自然语言处理方法提取了 GB/T31773—2015《中药方剂编码规则及编码》和 GB/T31774—2015《中药编码规则及编码》中方剂、饮片、药材等信息,并将其存储为“方剂—饮片”和“饮片—药材”的形式。其次,为了在方剂分类任务中融合中药方剂中药味组成的主次成分信息,本文基于中药方剂成分的相似性构建了知识图谱,该图谱以“中药方剂”为节点、以“相似关系”为边,并将饮片、药材等组成信息作为节点特征,该图谱属于同构图。然而,基于该图谱的研究结果表明,该研究有一定成效,但还有进一步的提升空间,为此,本文进一步基于配伍理论构建了“方剂—饮片—药材”中药知识图谱,该图谱以“中药方剂”及其组成成分(饮片、药材)为节点,以“组成关系”为边,该图谱属于异构图。在基于配伍理论构建的图谱中融入“君臣佐使”等先验知识作为图的初始结构,并将先验知识作为图谱中边的初始权重。

(2) 研究了适用于国标数据集的图神经网络模型。首先,本文针对相似性知识图谱构建了 TCM-GCN,该模型可以有效完成方剂分类任务,但对于基于配伍理论构建的知识图谱,由于 TCM-GCN 无法动态学习图结构中边的权重,而无法适用于该图谱。此外,基于中药知识图谱和图神经网络构建中药方剂的分类预测模型还面临如下挑战:(i) 中药知识图谱难以体现各饮片是方剂中的主要、次要成分;(ii) 难以解释饮片成分在方剂功用分类中的作用机制。为解决上述问题,本文进一步提出了一种图神经网络模型 TCM-GAT 用于中药方剂的功用分类预测。TCM-

GAT 采用 embedding 向量表示饮片在每首方剂中的君臣佐使属性，同时利用图注意力网络的注意力机制动态学习每首方剂中的各饮片在功用预测中应当分配的权重值。TCM-GAT 的训练过程融合了每首方剂中饮片的君臣配伍关系，因此，TCM-GAT 在方剂类别归属预测时能区分饮片成分的主次角色，提升模型预测的准确性。此外，TCM-GAT 引入了基于 Shapley 值的图神经网络的后验(post-hoc)解释方法，如 GraphSVX^[60]、GNNShap^[64]等，以解析各种药味成分如何作用于方剂功用分类。中药药味组成相对于其功用和疗效的可解释性对于中医药标准化工作有着重要的研究意义。本文方法有助于理解中药方剂中各饮片成分的作用机制，保证用药透明度与可信度，辅助调整药方配比，提升药效或者降低药物的副作用。

1.3.2 论文组织架构

本文基于可解释图神经网络方法对中药方剂的功用分类展开了一系列的研究。本文共有包含五个章节，各章节的内容安排如下：

第一章，绪论。首先介绍了课题的研究背景与意义。其次，分析了国内外中医证候与疾病预测、可解释图神经网络的研究现状，并梳理了中药方剂分类研究和中药知识图谱的相关研究的进展与不足，此外，还梳理了 GNN 等模型和可解释图神经网络方法在中医领域的研究进展与不足，最后介绍了本文研究的主要内容和结构安排。

第二章，相关理论基础与技术。本章先介绍了中医药的相关基础知识，包括中药方剂功用分类方法和配伍理论。紧接着，本章阐述了图神经网络及其可解释性的基础知识，包括图卷积神经网络和可解释图神经网络，并详细介绍了该算法的原理，为后续研究提供了理论和技术支撑。

第三章，TCM-GCN：基于成分相似性的中药方剂功用分类。本章首先介绍了基于相似性的中药方剂知识图谱的构建方法，之后，介绍了针对该图谱构建的 TCM-GCN 模型，在实验部分，将该模型与传统机器学习模型进行了对比，并进行消融实验，证明了该模型的有效性。

第四章，TCM-GAT：基于配伍理论的中药方剂功用分类。本章的研究是第三章的进一步提升。本章首先介绍了基于配伍理论的中药方剂知识图谱的构建方法，之后，介绍了针对该图谱构建的 TCM-GAT，在实验部分，不仅将该模型与传统机器学习模型进行了对比，还将其与传统 GAT 和 TCM-GCN 的效果进行了对比，证明了该模型有更良好的性能。此外，本章以 GNNShap 为例介绍了后验可解释图神经网络的原理，还介绍了实验环境及模型的参数设置，在实验部分，对比了多种可

解释图神经网络方法，并选择最优的解释方法，将得到的节点解释结果进行可视化分析。

第五章，研究不足与展望。主要对本文的研究内容进行归纳总结，指出目前研究工作的不足之处，并对未来的研究工作提出进一步的改进方向。

第2章 相关理论基础与技术

2.1 中医药理论基础

2.1.1 中药方剂功用分类方法

中药方剂数量庞大，其功用分类作为方剂学理论体系的核心，不仅是方剂整理、研究和临床运用的关键，也反映了中医学理论发展和临床实践不断深化的过程。最早的方剂分类方法是病证分类法，以《五十二病方》为代表，按疾病（如痢、疽）或症状（如寒热、咳喘）进行对方剂进行归类，但该方法理论性较为薄弱；此后，出现了脏腑经络分类法，以《千金要方》为代表，按方剂主治的脏腑（心、肝、脾、肺、肾）或经络对方剂进行归类，但该方法未能揭示治法核心；后来，清代程钟龄提出“汗、吐、下、和、温、清、消、补”八法，现代《方剂学》在此基础上将方剂的类别细化为“解表”、“泻下”等约二十个功用大类，功用分类法才得以确立。功用分类法是根据方剂的治疗作用来划分类别的一种方法，其中每类方剂都围绕某种“治法”展开，该分类法不仅体现了中医“辨证论治”的核心思想，还能把方剂与治病理论结合起来，因此，功用分类法成为现代方剂学的最常用的分类方式。

在此背景下，国家标准 GB/T31773—2015 和 GB/T31774—2015 规范了中药方剂及饮片数据。前者收录 1089 首方剂（源自 1800 余部古籍），按 20 种功用对其进行分类并明确其药味（中药饮片）组成，见表 2.1；

表 2.1 国家标准 GB/T31773—2015 中 20 种方剂功用分类

代码	01	02	03	04	05	06	07	08	09	10
功用大类	解表	泻下	和解	清热	祛暑	温里	补益	固涩	安神	开窍
代码	11	12	13	14	15	16	17	18	19	20
功用大类	理气	理血	治风	治燥	祛湿	祛痰	消食	驱虫	涌吐	痈疡

后者共编码了 1219 种中药材、1603 味饮片，并详述了通过炮制工艺将中药材加工为不同形态中药饮片的过程。例如，对于大黄这味中药材，通过酒炙的炮制工艺，可转化为酒大黄这一饮片形态；通过炒炭的炮制工艺，则可制得大黄炭这一饮片；若用酒炖或酒蒸的炮制工艺，则可得到熟大黄炭这一饮片形态。同一种中

药材经过不同的炮制工艺会形成不同的饮片，这些饮片最终以片状、段状等形式存在，从而更加契合临床应用的多样化需求。

2.1.2 中药方剂配伍理论

中药方剂的配伍理论是多种药味组成成分在同一首方剂中按照一定原则进行组合的理论，其目的是增强疗效和降低毒副作用。中药方剂的配伍理论是连接中药学与方剂学之间的纽带，是“方成于法，法归于理”的具体体现。目前，中药方剂的配伍理论主要包括两大体系：其一是“君臣佐使”，这是方剂组成的结构总纲，规定了方剂中各种药味组成的角色和地位；其二是源自《神农本草经》的“七情和合”，该理论描述了两味药物配伍后可能产生的七种基本关系，分别为单行、相须、相使、相畏、相杀、相恶和相反。这两大体系从结构角色与相互关系两个层面对配伍理论的进行划分，为现代中药方剂的研究提供了理论支撑。此外，配伍理论通过挖掘药物之间的复杂关系，能够更灵活应对复杂病情，达到了单一药物难以达到的治疗效果。

“君臣佐使”是配伍理论的核心内容之一，该理论根据药物在方剂中所起的主次作用与协同地位，将其划分为四类角色，其中包括君药、臣药、佐药和使药。在该配伍理论中，君药是方剂的核心，针对主病或主证发挥决定性治疗作用，通常药力最强，例如在麻黄汤中，麻黄为君药，具有发汗解表、宣肺平喘的功效，直接对应外感风寒导致的咳喘等主症。臣药可以辅助君药，增强主病或主证的治疗效果，还能对兼病或兼证发挥主要治疗作用，在麻黄汤中，桂枝为臣药，可以辅助麻黄发汗解表，增强祛风散寒的效果，这体现了臣药“辅君助治”的配伍原则。佐药有多重作用，主要分为以下三种，其一：作为佐助药，可以协助君药或臣药发挥治疗作用，增强整体治疗效果，还可以辅助治疗次要兼证；其二，作为佐制药，可以消除或减缓君药和臣药的毒性或烈性；其三，作为反佐药，当机体在危重状态下可能对君药产生排斥时，适当配伍作用相成但性味相反的药物，从而引导君药更好地发挥治疗效果。以白通加猪胆汁汤为例，当患者体内阴寒达到极点时，必须用大辛大热的药物来回阳救逆、破阴散寒，然而，若只使用热药，体内的阴寒之气会排斥该药物，甚至引发“药入即吐”的拒药反应。为解决这一问题，张仲景在大剂热药中加入极少量苦寒的猪胆汁与咸寒的人尿来缓和药性，从而反佐助阳，使热药发挥回阳的效果。使药主要有两种作用：其一作为引经药，可以引导方剂中其他药物的药力趋向特定的脏腑或经络部位，起到“药引子”的作用，例如，在治疗头痛时，不同的头痛部位对应不同的经络，若为少阳经头痛，可以使用柴胡将药力引到少阳经；

若为阳明经头痛，可以使用白芷将药力引到阳明经，从而实现针对性治疗；其二作为调和药，可以调和方剂中其他药物的性味与药性，许多方剂常用甘草作为调和使药，甘草不仅能调和药物，还有解毒等辅助功效。君臣佐使配伍理论关系见图 2.1。




图 2.1 中药方剂君臣佐使配伍理论关系图

2.2 图神经网络及其可解释性

2.2.1 图卷积网络

1) 图卷积神经网络

图神经网络是一类专门用于处理图结构数据的深度学习模型，其核心在于通过节点之间的连接（边）来传播和聚合信息，从而学习包含丰富拓扑结构信息的节点特征表示，其本质是提取图结构的空问特征。图卷积神经网络是图神经网络中的一种典型代表，其核心思想是通过邻居信息的聚合与特征变换，实现对图中节点表示的更新与学习，该模型在节点分类、链接预测和图分类等任务中表现出色。本研究主要面向节点分类任务，即在构建好图结构及节点特征的条件下，学习节点的低维表示，并进一步预测每个节点所属的类别标签。

GCN 默认其输入为无向图，如果输入的是有向图，GCN 通常会忽略边的方向性，将其视为无向边处理。在无向图中，边没有方向性，节点之间的信息传递具有对称性，即两节点信息之间信息可以双向流动。因此，在每层 GCN 中，节点会从其所有邻居（包括自身）平均或加权聚合邻居特征，从而更新自身特征。当使用 k 层 GCN 更新节点特征时，模型会聚合该节点 k 阶邻域内的所有节点的特征信息，

无向图的消息传递机制见图 2.2。




图 2.2 两层 GCN 的消息传递机制

在图 2.2 中，图中黑色边表示无向图的原始边，橘色箭头表示信息从二阶邻居逐层传递至节点 0 的路径，这也显示了节点 0 在进行特征聚合时所依赖的邻居节点。在图 2.2 的第一层 GCN 中，节点 0 聚合其自身和 1 阶邻居（1、2、3），在第二层 GCN 中，节点 0 继续聚合这些邻居的邻居，即 2 阶邻居（4、5、6、7、8）。最终，节点 0 的特征表示会包含来自其 2 阶邻域内所有节点的信息。

图卷积神经网络的结构主要包含输入层、隐藏层和输出层。其中，隐藏层由多个堆叠的图卷积层构成，是图卷积神经网络的计算核心，每一层图卷积均执行相同的操作，但学习不同的参数，隐藏层通过一系列可学习的变换，逐步聚合节点更远邻域的信息。为了缓解图神经网络在多层堆叠时可能出现的过度平滑和梯度消失问题，通常会在隐藏层之间引入残差连接^[65]（Residual Connection）等结构性设计。接下来将分别介绍 GCN 的输入层、隐藏层和输出层。

输入层负责接收图结构数据。对于 GCN 来说，其输入主要包含节点特征矩阵 $\mathbf{X} \in \mathbb{R}^{n \times d}$ 和邻接矩阵 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 两部分，其中 n 表示节点个数， d 表示初始的特征向量的维度。节点特征矩阵提供了图中每个实体的初始属性信息，以社交网络为例，特征可以是用户的年龄、性别等。邻接矩阵中的元素通常用二进制形式表示，公式如下：

$$A_{ij} = \begin{cases} 0, & \text{如果顶点 } i \text{ 和顶点 } j \text{ 之间有边相连} \\ 1, & \text{否则} \end{cases} \quad (2-1)$$

对于无权无向图，其邻接矩阵是一个对称矩阵；对于有向图，其邻接矩阵不一定对称；对于带权图，邻接矩阵中的元素可以是边的权重，也可以是 0-1 二值矩阵。GCN 在输入隐藏层之前，通常会对邻接矩阵进行预处理，得到归一化且带自环的邻接矩

阵。预处理包含两步，首先，添加自环，见公式（2-2），通过添加单位矩阵确保节点在聚合时能包含自身特征；其次，对称归一化，数学公式见（2-3）：

$$A = A + I \quad (2-2)$$

$$A = D^{-\frac{1}{2}} A D^{-\frac{1}{2}} \quad (2-3)$$

其中， D 表示 A 的度矩阵， D 是对角矩阵，第 i 行第 j 列的元素是节点 i 的度数， $D_{ii} = \sum_j A_{ij}$ 。通过对称归一化可以平衡不同度数对节点的影响，防止特征值在传播过程中爆炸或消失。

隐藏层由多个堆叠的图卷积层构成，是图卷积神经网络的计算核心，每一个卷积层都执行相同的操作，但学习不同的参数，隐藏层通过一系列可学习的变换，使原始输入逐步聚合更远邻居的信息。对 GCN 而言，在单层图卷积操作中，主要包含线性变换、邻居聚合和非线性激活三个步骤。首先，通过可学习的权重矩阵 W 对输入特征进行线性变换 XW ，从而将原始特征映射到新的特征空间；接着，利用归一化后的邻接矩阵对变换后的特征进行左乘操作 AXW ，实现节点与其邻居（包括自身）之间的信息交互，这是图卷积的核心；最后，将聚合后的结果输入非线性激活函数，常见的非线性激活函数有 Sigmoid、Tanh 和 ReLU 等，Sigmoid^[66]是最常用的一种激活函数，可以将任意值映射到 $[0,1]$ 区间，适用于二分类问题；Tanh^[67]是双曲正切函数，可以将值映射到 $[-1,1]$ 区间；ReLU^[68]是一种广泛应用于深度神经网络中的激活函数，本文使用 ReLU 作为激活函数，ReLU 相较于其他激活函数可使网络在反向传播时加速收敛，其数学公式如下：

$$\text{ReLU}(x) = \max\{x, 0\} = \begin{cases} x, & x \geq 0 \\ 0, & x < 0 \end{cases} \quad (2-4)$$

ReLU 函数图像如图 2.3 所示。




图 2.3 ReLU 激活函数图像

对于具有 l 层网络的 GCN，特征更新的表达式如下：

$$X^{(l+1)} = \sigma\left(AX^{(l)}W^{(l)}\right) \quad (2-5)$$

其中， σ 是激活函数。

输出层会将隐藏层学习到的节点特征表示映射到具体的任务空间，因此，具体任务不同，输出层的设计也不同。对于节点分类任务，会输出每个节点的类别概率分布；对于图分类任务，会输出每张图的所属类别；对于边的预测任务，会输出边是否存在或边的类型。在边的预测任务中，通常使用二元交叉熵（Binary Cross-Entropy）损失函数，该函数用于衡量模型对每对节点之间是否存在边的预测结果与真实标签之间的差异。在分类任务中，模型的输出通常会通过 softmax 分类器转化为概率分布向量，损失函数用于衡量模型预测结果与真实标签之间的差异，该任务中通常使用交叉熵损失（Cross-Entropy Loss）函数，公式如下：

$$L = -\frac{1}{n} \sum_{i=1}^n \sum_{j=1}^c y_{ij} \ln(p_{ij}) \quad (2-6)$$

其中， c 表示类别数量， $y_{ij} \in \{0,1\}$ 表示第 i 个样本在第 j 个类别上的真实标签， $p_{ij} \in (0,1)$ 表示模型对第 i 个样本属于第 j 个类别的预测概率，这些概率通常由 softmax 函数输出，且满足 $\sum_{j=1}^c p_{ij} = 1$ 。

在 GCN 模型中，除需要更新节点特征外，还需要通过反向传播更新权重矩阵 $W^{(l)}$ ，其更新公式如（2-7），其中， η 是学习率。

$$W^{(l)} \rightarrow W^{(l)} - \eta \frac{\delta L}{\delta W^{(l)}} \quad (2-7)$$

在更新参数的过程中，反向传播负责计算梯度，而梯度更新是优化模型参数的过程。在前向传播中，模型会根据当前参数计算出预测结果，并通过损失函数衡量预测值与真实值的差距，从而得到当前参数下的损失值。然后，反向传播利用链式法则，从输出层开始逐层向后传播误差信息，计算损失函数对各层参数的偏导数，即梯度。梯度下降更新参数的过程如图 2.4。




图 2.4 梯度下降过程

图 2.4 中, 曲面 (Z 轴) 表示损失函数, X 轴和 Y 轴表示模型中的两个参数, 红色轨迹表示梯度下降的参数更新路径, 红色轨迹上的黑点表示一次参数更新后的结果, 起点表示随机初始化参数, 终点表示全局最优解。在更新过程中, 步长逐渐减小, 主要原因在于随着参数逐步接近最优解, 损失函数在参数空间中的梯度范数不断减小, 因此, 在学习率保持不变的情况下, 更新幅度就随之减小。

图 2.5 以 2 层 GCN 为例, 完整地展示了其做节点分类任务的原理图。




图 2.5 GCN 做节点分类的原理图

在图 2.5 中, 白色节点表示原始节点, 黄色表示当前更新的节点, 绿色表示当前更新节点所使用的邻居。在 GCN layer 1 (第一层卷积网络) 中, 每个节点使用自身节点特征及其一阶邻居节点聚合信息, 生成新的节点表示, 所有节点的特征更新并行进行, 并对第一层的输出加上非线性变换; 在 GCN layer 2 (第二层卷积网络) 中, 每个节点使用第一层更新后的特征自身节点特征及其二阶邻居节点聚合信息, 第二层和第一层的节点更新顺序在机制上相同, 其他执行操作也与第一层相同, 这也体现了 GCN 的本质: 更新机制不变, 只是输入特征发生了变化。该图中, GCN 最终输出的是节点级表示, $\hat{y}_1$ 、 $\hat{y}_2$ 和 $\hat{y}_3$ 分别表示节点预测的类别。

2) 图注意力网络

图注意力网络是图卷积神经网络的一种扩展形式, 其核心思想是在邻居特征聚合过程中引入注意力机制, 以实现针对不同邻居节点的加权聚合。图注意力网络与传统的图卷积神经网络中对邻居节点等权平均聚合的方式不同, GAT 能根据邻居节

点的重要性动态分配权重，从而提升模型对图结构的建模能力。

图注意力网络的结构与图神经网络相同，主要包含输入层、隐藏层和输出层。GAT 与 GCN 的主要区别是隐藏层的设计不同。相比之下，GCN 的隐藏层采用的是基于图拉普拉斯矩阵的归一化平均聚合方式，对所有邻居赋予固定权重，难以区分不同邻居的重要性，而 GAT 对所有邻居赋予动态权重。因此，GAT 在处理结构复杂的图数据时，通常能获得更优的性能表现。接下来分别介绍 GAT 的输入层、隐藏层和输出层。

GAT 的输入层与 GCN 相同，其输入主要包含节点特征矩阵 $X \in \mathbb{R}^{n \times d}$ 和邻接矩阵 $A \in \mathbb{R}^{n \times n}$ ，此层不进行特征变换，仅作为后续图注意力层的输入。GAT 的输入图也需要为每个节点添加自环，以确保节点自身特征参与聚合，但与 GCN 不同，GAT 使用内置函数自动添加自环；此外，GAT 不需要对邻接矩阵进行归一化操作，而是通过注意力机制动态学习邻居节点的聚合权重。

GAT 的隐藏层主要由图注意力机制构成，每一个注意力层的计算过程包括线性变换、注意力系数计算、注意力系数归一化、特征聚合等四个步骤。具体而言，在单层图注意力操作中，首先，通过可学习权重矩阵 W 对输入特征进行线性变换 XW ，将所有节点的特征统一映射到新空间，使注意力机制可以在相同维度和语义下比较邻居特征；接下来，针对每个节点与其邻居之间的边，基于它们的节点特征 $X = \{x_1, x_2, \dots, x_n\}$ ，计算未归一化的注意力系数（注意力打分），公式如下：

$$e_{ij} = \frac{\exp(\text{LeakyReLU}(a^T [Wx_i \parallel Wx_j]))}{\sum_{k \in N_i} \exp(\text{LeakyReLU}(a^T [Wx_i \parallel Wx_k]))} \quad (2-8)$$

其中， N_i 表示节点 i 的邻居节点， a 表示权重向量， $\cdot^T$ 表示转置操作， $\parallel$ 表示连接操作，LeakyReLU 是激活函数，LeakyReLU 计算公式如下：

$$\text{LeakyReLU}(x) = \begin{cases} x, & x \geq 0 \\ \lambda x, & x < 0 \end{cases} \quad (2-9)$$

其中， $\lambda \in (0,1)$ ，在注意力打分函数中引入 LeakyReLU 激活函数，有助于缓解 ReLU 在负区间梯度为零的问题，从而避免注意力权重在训练过程中“失活”或无法更新，这种设计能提升模型的稳定性。

注意力系数用来衡量邻居节点在特征聚合过程中的重要性，但在后续的使用中需要通过 softmax 函数对其进行归一化，得到注意力权重（归一化的注意力系数），其公式如下：

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k \in N_i} \exp(e_{ik})} \quad (2-10)$$

计算注意力权重的完整过程见图 2.6。




图 2.6 注意力权重的计算过程

在图 2.6 中，对于节点 i ，其特征为 x_i ，其邻居节点为 $\{j_1, j_2, j_3, j_4\}$ ， $x_{j_1}, x_{j_2}, x_{j_3}, x_{j_4}$ 分别为邻居节点特征，首先通过公式 (2-8) 计算节点 i 与其每个邻居节点间的注意力打分 e_{ij} ，再通过 softmax 对 e_{ij} 归一化，见公式 (2-10)，得到节点 i 与其邻居节点的注意力系数。最后，利用注意力权重对邻居节点的特征进行加权求和，实现节点间信息的聚合，再将聚合后的结果输入非线性激活函数，节点的特征更新公式如下：

$$x_i' = \sigma\left(\sum_{j \in N_i} \alpha_{ij} W x_j\right) \quad (2-11)$$

公式 (2-11) 表示在 GAT 中只使用一套注意力机制（注意力头）更新节点特征的情况，但由于使用单个注意力头通常只能从一个角度衡量邻居的重要性，因此，经常使用多头图注意力网络（Multi-Head Graph Attention Network）从不同角度聚合邻居信息，从而捕捉其多维特征。在多头图注意力网络中，每个注意力头独立计算注意力权重并生成特征表示，再将这些注意力头的输出特征进行整合，以形成节点的最终表示。对于具有 l 层网络、 K 个注意力头的 GAT，第 k 个注意力头节点特征更新表示如下：

$$x_i'^{(l-1,k)} = \sigma\left(\sum_{j \in N_i} \alpha_{ij}^{(l-1,k)} W^{(l-1,k)} x_j^{(l-1,k)}\right) \quad (2-12)$$

将多个注意力头的输出特征进行整合的方式包括拼接和平均两种，具体而言，中间层（前 $l-1$ 层）将所有注意力头的输出拼接起来，公式如下：

$$x_i'^{(l-1)} = \parallel_{k=1}^K x_i'^{(l-1,k)} \quad (2-13)$$

输出层（第 l 层）将所有注意力头的输出求平均，公式如下：

$$x_i^{(l)} = \frac{1}{K} \sum_{k=1}^K x_i'^{(l-1,k)} \quad (2-14)$$

在 GAT 中，除上述需要更新的节点特征外，还需要更新的参数有 $\alpha_{ij}^{(l,k)}$ 和 $W_{ij}^{(l,k)}$ ，每个注意力头均使用反向传播机制独立两个参数。图 2.7 以 3 个注意力头为例，演

示了使用多头图注意力网络时，单个节点的邻居信息聚合过程。




图 2.7 多头图注意力网络的聚合过程

在图 2.7 中， x_i 表示当前更新的节点 v_i 的特征，不同颜色的波浪线代表不同的注意力头，节点 v_i 通过多个注意力头分别对其邻居节点（包括自身）分配不同的注意力权重，并对邻居特征进行加权聚合，最终通过拼接或平均方式融合多头结果。GAT 通过引入注意力机制，在聚合表达式用注意力权重 α_{ij} 替代了 GCN 中的固定邻接矩阵 A ，实现了从静态结构传播到动态可学习传播的转变。

在节点分类任务中，GAT 与 GCN 的输出相同，也会输出一个维度为类别数的向量，并经过 softmax 激活函数，生成每个节点的类别概率分布。

2.2.2 可解释图神经网络

近年来，以 GNNExplainer 为代表的可解释图神经网络方法（如 PGExplainer、PGMExplainer^[69]、GraphSVX、GNNShap 等）成为领域内研究热点，这些方法能够解释与每个实例的预测结果相关的图结构中各个边的重要性。不同的解释方法在计算成本和解释效果上有着各自的优势，因此，在实际应用中，选择解释方法时往往要考虑计算效率、模型复杂度、任务需求与可解释性粒度等因素。

可解释图神经网络的提出旨在提高模型决策过程的透明度和可解释性，研究模型做出预测的依据。相较传统图神经网络，图神经网络的可解释性起步较晚，按解释对象可以将其分成节点级、边级、特征级和图级等类别的解释框架，按解释方式可以将其分成内建解释（Intrinsic Explanation）和后验解释（Post-hoc Explanation）两类解释框架。内建解释是在模型设计时就嵌入可解释性机制，使模型结构天然具有可解释性，这种方法通过在模型中引入注意力机制或可学习掩码等，使得模型在预测的同时能够输出可视化或可量化的解释结果，无需额外的后续处理步骤。然而，

内建解释通常会改变模型的原始结构,这可能会影响原模型的性能,而图神经网络已广泛应用于多个重要领域,这些领域既需要模型做出高精度的预测,又需要良好的可解释性。为此,研究者提出了许多 GNN 的后验解释方法,如 GraphSVX^[60]和 GNNShap^[64]等,该方法是在不改变原始模型结构或参数的前提下,分析模型的决策依据,从而提供多粒度的解释结果。

后验解释方法通常需要三个输入:图结构、训练完成的 GNN 模型和预测结果。图结构是解释的基本对象,解释器需要根据图的结构和特征才能识别对模型预测结果具有关键影响的结构部分。训练完成的图神经网络模型是解释的核心目标,解释器旨在分析该模型在当前输入下的决策机制与依据。预测结果则作为解释的参照标准,解释器需明确模型对特定输入所产生的输出,从而判断哪些图结构或特征在决策过程中发挥了重要作用。后验可解释图神经网络的基本流程图如图 2.8 所示:




图 2.8 后验可解释图神经网络的基本流程图

在图 2.8 中,首先将图结构 (X, A) 输入到 GNN 模型中,得到一个训练完成的 GNN 模型和预测结果 y ,其次将图结构、训练好的 GNN 和预测结果三者输入到后验可解释图神经网络中,根据不同的任务类型可以得到节点、边、特征和子图的重要性。GraphSVX 和 GNNShap 均属于基于 Shapley 值的方法,以 GNNShap 为例介绍模型对节点的解释过程。

在解释过程中,每次选择一个节点 v ,研究 v 的某一邻域内邻居对分类结果的影响。其步骤如下:首先,将初始特征 X 和图结构 A 输入到 GNNShap 中, GNNShap 对图剪枝,其目的是移除与节点 v 无关的边,生成更小的修剪子图,该修剪子图由节点 v 及组成它 k 阶邻居节点构成。其次,对修剪子图采样,采样的目的是通过随机采样少量有代表性的子图替代遍历所有可能组合来大幅降低计算成本,采样阶段会生成掩码矩阵 M 和权重向量 W ,由矩阵 M 得到样本,即修剪子图的多个子图。接下来,把这些样本输入到训练好的 GNN 模型中,对每个样本产生一个目标节点预测值 y 。最后,利用上述得到的 M 、 W 和 y 计算每条边的 Shapley 值,即对于节

点 v 分类的贡献。

在后验可解释图神经网络中，Shapley 值被广泛应用于量化图中各组成部分对模型预测结果的影响。基于 Shapley 值的方法通过评估节点、边、特征或子图在所有可能组合中的平均边际贡献，从而生成可以量化的解释结果，基于 Shapley 值的方法后验解释方法有 GraphSVX 和 GNNShap 等。Shapley 值源自合作博弈论，其核心思想是衡量某个参与者（如特征、节点或边）在所有可能合作联盟中的边际贡献，从而量化参与者对整体收益的影响。具体而言，通过计算该参与者在不同联盟中的加权平均得到该参与者对整体的贡献，Shapley 值的符号反映了参与者对模型预测的正向或负向作用，即促进或抑制作用，其绝对值大小反映了影响的强弱。其数学表达式如下：

$$\varphi_i = \sum_{S \in \{1, \dots, n\} \setminus \{i\}} \frac{|S|!(n-|S|-1)!}{n!} [f(S \cup \{i\}) - f(S)] \quad (2-15)$$

其中， n 为参与者数， S 为联盟（参与者的子集）， $|S|$ 为联盟的规模大小， $f(S \cup \{i\}) - f(S)$ 为参与者 i 对联盟 S 的边际贡献。

图 2.9 提供了一个使用 Shapley 值估计集成模型中各个弱模型对模型整体性能的贡献。Shapley 值可用于解决合作博弈问题，集成模型是其在机器学习中的一种应用形式，在该博弈中，集成中的各个模型作为参与者（黄色、绿色和蓝色人），预测所带来的收益作为博弈的回报（金币），并对应于不同联盟（矩形）所获得的收益。Shapley 值能够将全体模型组成的大联盟（右下角）所获得的总收益，公平地分配给各个模型。




图 2.9 利用 Shapley 值估计集成模型中各个弱模型对于模型整体性能的贡献

在合作博弈论中，Shapley 值的计算复杂度为指数级，因为该计算需要枚举所有可能的参与者联盟以评估每个参与者的边际贡献。在图神经网络的解释任务中，针对需要评估 2^{n-1} 个（ n 是参与者总数）参与者联盟的组合而导致计算量呈指数级增长的问题，GNNShap 采用了线性核 SHAP 的加权最小二乘方法近似求解，见公

式(2-16)，最终使总 Shapley 值等于预测输出。其中， M 中的每个 $m \in \{0,1\}^{1 \times n}$ 为二进制掩码， $\varphi_0 = f(0)$ 是一个常数项，代表空参与者的情况， φ_i 是要求解的第 i 个节点的 Shapley 值。

$$f(x) \approx g(x) = \varphi_0 + \sum_{i=1}^n \varphi_i m_i \quad (2-16)$$

这本质上是一个加权最小二乘问题^[70]，GNNShap 通过最小化公式(2-17)中损失函数构建线性模型来实现。其中， S 是联盟，即联盟的组合，公式(2-18)中 $\pi_{|S|}$ 为边组合的权重。

$$L(f, g, \pi_m) = \sum_{m \in M} [f(S) - (g(S))]^2 \pi_{|S|} \quad (2-17)$$

$$\pi_{|S|} = \frac{n-1}{\binom{n}{|S|} |S| (n-|S|)} \quad (2-18)$$

在得到沙普利值后，即可得到解释子图 G_s 。使用 GNNShap 做解释的具体步骤如下：

1) 剪枝

给定一个图 $G(V, E)$ 和一个节点子集 $V' \in V$ ，诱导子图 $G(V')$ 是由 V' 中的所有节点以及它们在原图中存在的边所构成的子图，诱导子图中会包含一些并不向目标节点 v 传递信息的冗余边和节点，为了提升解释的精准度和效率，通过剪枝将不传递信息的边和节点剔除，得到目标节点的修剪的计算子图 G_c ，再将 G_c 中所有边视为参与者。在图 2.10 中，展示了节点 v 的两跳诱导子图在剪枝前后的对比。未剪枝的诱导子图保留了所有距离该节点两跳之内的节点及其连接边，其中包括一些虚线表示的冗余边。尽管这些边属于诱导子图，但在两层图神经网络中，其信息无法传递至目标节点。若将这些边都视为计算 Shapley 的参与者，不仅无法提供有效信息，反而会显著增加计算复杂度。




图 2.10 两跳剪枝诱导子图^[64]

2) 采样

为有效降低计算复杂度并节约计算资源，GNNShap 使用采样策略来提升模型的整体计算效率，该策略能高效估计 Shapley 值。具体而言，通过蒙特卡洛采样在参与者的所有联盟组合中随机选取一部分联盟近似估计其边际贡献。为提升估计的公平性与稳定性，该方法不仅进行随机采样，还对不同规模的联盟 $|S|$ 合理分配权重与样本数量。为每种联盟大小分配总权重的公式如下：

$$\rho_{|S|} = \frac{n-1}{|S|(n-|S|)} \quad (2-19)$$

其中， n 是参与者总数， $\rho_{|S|}$ 表示所有大小为 $|S|$ 的联盟所对应的总权重。接下来，基于核 SHAP 的采样方法生成样本，使得样本数量与联盟规模的总权重成比例，各生成样本数量的公式如下：

$$k_{|S|} = k * \frac{\rho_{|S|}}{\sum_{i=1}^{n-1} \rho_i} \quad (2-20)$$

其中， k 是总采样数， $k_{|S|}$ 表示应从大小为 $|S|$ 的联盟中采样的样本数量，该抽样方法能从所有可能的联盟规模中进行抽样，并合理分配采样资源。

在分配样本数量时，极大（包含几乎所有参与者的联盟）或极小（只有 1 个参与者的联盟）规模的联盟可能被分配了较多的样本数，但这些联盟的组合总数是有限的，如果给大小为 1 的联盟分配的样本数量 $k \gg n$ （分配的样本数超过了这些组合的总数），就会出现冗余样本，此时，需要将剩余样本重新分配给其他联盟规模。最后，通过将该联盟规模的总权重平均分配给实际采样的样本数量，计算每个联盟样本的个体权重 $w_{|S|}$ 。公式如下：

$$w_{|S|} = \frac{\rho_{|S|}}{k_{|S|}} \quad (2-21)$$

采样输出是一个 $k \times n$ 的二进制掩码矩阵 M ，其中， k 表示采样子图的数量， n 表示剪枝得到的计算子图中参与者的数量，需要注意的是， $k \gg n$ ，即采样数量远大于参与者数量。当第 i 条边存在于第 j 个子图时， $M[i, j]=1$ ，否则， $M[i, j]=0$ 。采样阶段还会生成权重向量 W ，其中 $W[i]$ 存储第 i 个样本的权重值。

由于基于 Shapley 值的方法需要对子图样本进行多次模型预测，此过程会导致计算开销增大，因此，采用批处理（batching）与并行预测策略来加速计算。方法如下：将多个样本的子图的邻接矩阵沿对角线拼接，构建一个更大的块对角矩阵，同时将所有节点的特征向量进行拼接，并使用这些拼接后的矩阵，对一批样本中的目标节点进行并行预测，这种批处理方式不仅提升了数据局部性，还增强了并行计

算能力。

在完成上述步骤后，可分别获得 GNN 的预测结果 $\hat{y}$ 、通过采样生成的二进制掩码矩阵 M 和权重向量 W ，基于上述信息，进一步采用加权最小二乘方法对 Shapley 值进行计算，其解析解形式如下所示：

$$\phi = (M^T W M)^{-1} M^T W \hat{y} \quad (2-22)$$

2.3 本章小结

本章主要介绍了可解释图神经网络在中药方剂功用分类任务中的相关理论基础，涵盖中医药知识与图神经网络方法两个方面。首先，阐述了中药方剂功用分类的基本方法及其配伍理论，重点介绍了“君臣佐使”在方剂结构中的作用与意义。其次，介绍了图神经网络及其可解释性方法。在图神经网络部分，介绍了 GCN 与 GAT 的基本原理与建模机制；在可解释图神经网络部分，重点介绍了后验可解释方法的基本思想，并以 GNNShap 为代表，详细说明了其解释流程与原理。

第3章 TCM-GCN：基于成分相似性的中药方剂功用分类

3.1 引言

近年来,随着中医药现代化进程的加快,中药方剂的功用分类研究逐渐成为中医药信息化领域的重要工作。目前,现有分类方法更依赖于人工标注,但面对海量的中药方剂数据,人工标注其功效分类面临着成本高等问题,这为中药方剂功效分类的标准化带来了挑战。随着机器学习等技术的发展,利用传统机器学习模型如随机森林、支持向量机等能够有效地进行方剂的功效分类,但存在以下局限性:传统机器学习模型通常基于人工构建的固定维度特征向量进行建模,忽略了方剂中药味间的结构关系,因而难以建立其深层的语义表示,从而影响方剂分类的准确性。

在医药等科学领域,由于知识图谱能够有效地表示链接数据,图神经网络又有对图结构数据的强大建模能力,因此,图神经网络成为了相关领域的主要技术之一。然而,现有的图神经网络模型难以表示中药知识图谱中的药味成分的主次关系,即难以体现各饮片是方剂中的主要、次要成分。此外,该模型还缺乏对分类结果的理论解释与可视化分析,难以揭示模型决策与功用分类之间的内在联系,从而限制了研究成果在中医临床领域的应用。

为解决上述问题,本章提出基于 TCM-GCN 的方剂功用分类方法。本章的主要工作如下:

(1) 针对图神经网络模型难以表示中药知识图谱中的药味成分主次关系的问题,本章选用国标中的数据集,基于药味成分的相似性构建了中药方剂知识图谱,并将方剂的药味组成成分信息作为其特征,使模型能够在该图谱上学到更丰富的语义信息,进一步加强模型的特征提取能力,从而使模型可以更好地完成分类任务。

(2) 针对本章构建的中药知识图谱,设计并实现了 TCM-GCN 模型,用于中药方剂功效的分类任务,从而使该模型能够有效捕捉图结构的特征,并提升分类性能。实验部分展示了 TCM-GCN 在方剂分类任务中的表现,并将其与传统机器学习方法进行了对比,验证本章所提方法的有效性。此外,还对实验结果进行了可视化分析。

3.2 基于成分相似性的中药知识图谱

本文基于国家标准 GB/T31773—2015 和 GB/T31774—2015 中千余首方剂数据集进行研究的理由如下: (1) 相比于其他数据源,一方面,国标标注的数据集更

权威准确，从而使预测结果可信度更高；另一方面，基于国标构建的数据集更具可复用性，有利于研究成果的推广与标准化应用；（2）中药方剂分类问题专业性强，例如，《温病条辨》中给出的“新加香薷饮”的功效为“祛暑解表，清热化湿”，非专业人员在判断该方剂应归属为“解表方”或“祛暑方”类别时存在困难，难以提供与国标一致的权威分类结果。（3）国标不仅提供了统一的方剂命名、组成与功用描述，还明确规定了方剂所属的功效类别，这更有助于构建图结构，便于图神经网络模型在训练过程中学习语义特征。因此，选用国标收录的千余首中药方剂作为研究基础，不仅保障了数据质量，也为后续模型的可解释性分析与临床应用提供了坚实的数据支撑。

国标 GB/T31773—2015 收录了 1089 首方剂，其中包含了方剂名称、方剂来源（中医经典著作）、药味组成、方剂功效、主治症候等，且标注了方剂归属的 20 种功用分类（表 1）；国标 GB/T31774—2015 共编码了 1219 种中药材，以及这些中药材加工后得到的 1603 味饮片。这两个国标数据集均以 pdf 格式的文件中的表格形式存储，本研究首先利用格式转换工具将 pdf 格式的文件转换为 docx 或者 markdown 格式的文本文件，然后利用 python 库对这两个国标文本数据进行结构化处理。在所读取的信息中，选择了方剂功用分类的标记数据，以及与方剂功用分类最相关的“中药方剂—中药饮片”和“中药饮片—中药材”两种链接关系。

以“中药方剂-中药饮片”结构化处理过程为例，其流程如下：首先，对国标 GB/T31773—2015 中的中药方剂分类编码一览表进行解析，读取表格内容，提取“代码”、“方名”、“分类”和“组成”等字段信息。其次，对“组成”字段进行清洗与分割，并结合 Jieba 分词工具等完成中药饮片的命名实体识别，同时，通过中药方剂功用属性分类类目代码表将“解表方”等功效类别转换为标准类别编码“01”等。最后，将各字段按“代码；方剂名称；中药饮片组成；类别编码”的格式进行拼接，得到结构化结果。以大半夏汤为例，表 3.1 展示基于国家标准 GB/T31773—2015 提取的大半夏汤的方剂数据。

表 3.1 中药方剂数据示例

代码	方名	药味组成（饮片）	类别
0601120060	大半夏汤	法半夏 人参 蜂蜜	11 降气方

不同的炮制工艺会将同一种中药材制成不同的中药饮片，以半夏为例，半夏在临床使用上有毒，为确保用药安全，临床上常通过炮制来降低或消除其毒性或副作用。根据不同的炮制方法，半夏可加工为多种饮片形式，如法半夏、清半夏和姜半

夏等，但由于半夏的炮制方法不同且复杂，其功效及临床应用也不同。在中药方剂的组成中，一种中药方剂由多种中药饮片组成，一种中药饮片由一种中药材经特定炮制工艺加工而成，而一种中药材通过不同的炮制工艺可以制备出多种饮片。以大半夏汤为例，图 3.1 展示了中药方剂、中药饮片、中药材三者的存储关系示意图。




图 3.1 中药材、中药饮片、中药方剂关系示意图

尽管 GB/T31773—2015 国家标准详尽地记录了中药方剂的来源、功效和主治症状等诸多信息，但构建中药方剂拓补网络结构时并未纳入这些信息，仅采用中药方剂的药味组成和药味成分相关的中药饮片、中药材作为特征进行建模，原因如下：

（1）不同文献来源中的中药方剂药味组成信息比于其他信息一致性更高；（2）药味组成是中药方剂发挥功效的关键，且药味组成信息中包含其他功效等信息；（3）中药方剂的药味组成信息易于获取，基于该信息进行分类有助于提升方法的实用性与应用价值。

本章基于中药方剂的药味组成相似性构建了中药方剂知识图谱。首先，以中药方剂数据（表 3.1）为基础，将每首方剂视为图中的一个节点，并引入“主成分相似性”作为边。在定义主成分时，选取每首方剂中排在前 3 位的中药饮片作为其主要成分，该排序依据国家标准 GB/T31773—2015 中“组成”字段的药味原始顺序。主成分相似性判定规则是：对于任意两首方剂，若其主成分中有 2 个及以上中药饮片相同时，则判定两首方剂在药味组成上具有相似性，判定主成分相似性的示例见表 3.2。

表 3.2 主成分相似的中药方剂示例

方名	药味组成（饮片）
大青龙汤	麻黄,桂枝,炙甘草,苦杏仁,石膏,生姜,大枣
麻黄加术汤	麻黄,桂枝,炙甘草,燀苦杏仁,白术

由于大青龙汤和麻黄加术汤这两种方剂的前三个药味组成中均含有麻黄、桂枝、炙甘草，因此，判定大青龙汤和麻黄加术汤具有相似性。在构建知识图谱时，将二者设置成邻居节点。通过类似的方式，本章对所有方剂对进行了主成分相似性判断，并构建了一个以中药方剂为节点、以药味相似性为边的知识图谱，该图谱为后续图神经网络模型的训练与可解释性分析提供了基础。基于中药方剂的药味组成相似性构建的中药方剂知识图谱见图 3.2。




图 3.2 基于成分相似性的中药方剂知识图谱

3.3 TCM-GCN 模型构建

针对图 3.2 所构建的中药方剂知识图谱，本节设计了 TCM-GCN 对中药方剂的功能效用进行分类。研究步骤如下：首先，针对该图谱构建了图结构的特征矩阵。其次，定义了 TCM-GCN 网络结构，并设置了层数、隐藏维度和激活函数等。最后，设计了节点分类器，通过对 TCM-GCN 进行训练，最终使每个节点的特征向量收敛为低维稠密向量表示，并通过分类器输出得到方剂所属类别。

3.3.1 特征矩阵的构建

在图 3.2 的知识图谱中，每个方剂节点的特征由两部分组成，分别是中药饮片

和中药材。假设有 n 首中药方剂， a_1 个中药饮片、 a_2 个中药材，分别对中药饮片和中药材进行 Multi-Hot 编码，并将饮片编码与药材编码在特征维度上进行横向拼接，可以得到维度为 $a_1 + a_2$ 的复合特征向量，则对于任意一首中药方剂 v_i ，其初始特征 $x_{v_i} \in \mathbb{R}^{a_1+a_2}$ 。进一步地，将所有方剂节点的特征向量按行堆叠，可构建出整个图的初始特征矩阵 $X \in \mathbb{R}^{n \times (a_1+a_2)}$ 。在本研究中，依据国标数据集，共收录了 1089 首方剂，共编码了 1219 种中药材和 1603 味饮片，因此，本章构建的知识图谱共存在 $n = 1089$ 个方剂节点，构建的特征矩阵维度为 $X \in \mathbb{R}^{1089 \times (1219+1603)} = \mathbb{R}^{1089 \times 2822}$ 。该特征构建方式保留了方剂在药味组成层面的细粒度信息。

3.3.2 分类器的设计

本章构建的 TCM-GCN 模型以中药方剂知识图谱为基础，旨在实现对方剂功效的自动分类。TCM-GCN 模型的输入包括两部分：一是中药方剂的节点特征矩阵 $X = \{x_1, x_2, \dots, x_n\}$ ，其中， $x_i \in \mathbb{R}^d$ 表示每一首方剂的特征向量，维度 $d = 1219 + 1603 = 2822$ ，对应中药材与中药饮片 Multi-Hot 编码的拼接结果；二是图的邻接矩阵 $A \in \mathbb{R}^{n \times n}$ ，在本章中， $A \in \mathbb{R}^{1089 \times 1089}$ ，模型经过多层处理会生成新的节点特征 $X' = \{x'_1, x'_2, \dots, x'_n\}$ ， $x'_i \in \mathbb{R}^c$ ， c 是中药方剂的类别数，即 $c = 20$ 。TCM-GCN 模型采用两层图卷积结构，其整体计算过程可形式化表示为：

$$Z = \text{softmax}\left(A\text{ReLU}\left(AXW^{(0)}\right)W^{(1)}\right) \quad (3-1)$$

其中， $A \in \mathbb{R}^{1089 \times 1089}$ 表示对邻接矩阵进行对称归一化后的结果， $W^{(0)} \in \mathbb{R}^{2822 \times 256}$ 是第一层图卷积的可学习权重矩阵，用于将高维输入特征映射到 256 维的隐藏表示空间，ReLU 为非线性激活函数， $W^{(1)} \in \mathbb{R}^{256 \times 20}$ 是第二层图卷积的权重矩阵，用于将隐藏表示进一步映射为长度为 $c = 20$ 的输出向量，对应 20 种中药方剂的类别。模型的第一层图卷积操作通过邻接矩阵 A 聚合每个节点邻居的特征，并结合 $W^{(0)}$ 进行线性变换，生成中间特征表示。第二层则在此基础上再次进行特征聚合与线性映射，输出每个节点在各类别上的预测得分，并通过 softmax 分类器对其进行归一化，得到每个方剂节点属于不同类别的概率分布。

TCM-GCN 结合 softmax 和交叉熵损失函数完成分类预测任务。softmax 归一化公式如下：

$$\text{softmax}(x_i) = \frac{\exp(x_i)}{\sum_j \exp(x_j)} \quad (3-2)$$

设本章的图谱中任一节点为 v_i ，该节点经过 TCM-GCN 的前向传播后，会输出一个未归一化的类别得分向量 $B_i = \{b_{i1}, b_{i2}, \dots, b_{ic}\}$ ，经过 softmax 归一化后可得到其属

于每个类别的概率 $\{p_i, p_i, \dots, p_c\}$ 。在分类任务中，通常选择概率最大的类别作为最终预测结果。

基于 TCM-GCN 做中药方剂节点分类预测的完整架构见图 3.3。在图 3.3 中，假设初始的图结构共有 5 个节点 $V = \{v_1, v_2, v_3, v_4, v_5\}$ ，其邻接矩阵和特征矩阵分别见图中的 A 和特征矩阵 X ，首先使用添加自环和对称归一化的方式对邻接矩阵 A 进行预处理得到 $\tilde{A}$ ，再将 $\tilde{A}$ 和 X 输入到 TCM-GCN 的模型中，最后经过 softmax 归一化后分别得到 5 个节点的类别的概率分布。




图 3.3 TCM-GCN 的架构图

考虑到中药方剂在实际应用中往往具有多重功用属性，而单一类别的预测可能无法全面反映其临床功能。因此，本章进一步引入 Top-k 分类策略，以获取每个方剂在多个高置信度类别上的预测结果。具体而言，从归一化后的概率分布中选取前 k 个概率值最大的类别，记为 $\{p_{s_1}, p_{s_2}, \dots, p_{s_k}\}$ ，则对应的 Top-k 分类结果为 $\{\text{类别}_{s_1}, \text{类别}_{s_2}, \dots, \text{类别}_{s_k}\}$ 。Top-k 分类策略具有多方面的实际意义。一方面，该策略能够更全面地保留模型在多个类别上的高置信度预测结果，提升模型在多标签任务中的能力；另一方面，更贴合中医药“多效合一”和“一方多治”的理论特征，有助于揭示方剂在不同功能类别间的潜在关联。此外，在临床辅助决策等实际应用中，Top-k 分类结果为医生提供了容错空间与参考范围，增强了模型的实用性与可解释性。

3.4 实验设置与结果分析

3.4.1 参数设置

本章将整体数据集按照 8:2 的比例划分为训练集与测试集，其中，训练集用于

模型参数的学习，测试集用于评估模型的泛化能力。为确保实验结果的稳定性与可重复性，划分过程采用固定随机种子进行控制。对于 TCM-GCN，图卷积层数设为 2 层，隐藏层嵌入向量维度设为 256，边的初始权重统一设为 0.05。优化器选用 Adam^[71]，其学习率（learning rate, lr）设置为 0.01，丢弃率（dropout）设置为 0.5，以缓解过拟合问题。最大训练轮数（epoch）设为 200，并引入早停机制：当验证集的损失值在连续 10 个训练周期内不再下降时，提前终止训练过程，以提升训练效率并防止过拟合。

本章选用随机森林(Random Forest, RF)、支持向量机(Support Vector Machine, SVM)和 XGBoost(eXtreme Gradient Boosting)作为对比模型，所有对比模型均使用与 TCM-GCN 相同的节点特征矩阵作为输入，并通过参数调优以获得最佳性能。各模型的参数配置如下：

(1) RF: 学习率设为 0.1, 评估准则(criterion)为 gini, 决策树数量(n_estimators)为 1000, 最大树深度(max_depth)为 6, 最小叶节点样本数(min_samples_leaf)为 1, 启用自助采样(bootstrap = True)；

(2) SVM: 核函数(kernel)选择线性核(linear)，并启用概率估计功能(probability = True)，以支持多分类概率输出；

(3) XGBoost: 学习率设为 0.1, 树的数量(n_estimators)为 1000, 最大深度(max_depth)为 6, 样本子采样比例(subsample)为 0.8, 特征子采样比例(colsample_bytree)为 0.8, 目标函数(objective)设为多分类 softmax(multi:softmax)。

3.4.2 评估指标

准确率(Accuracy)是分类任务中最常用的评价指标之一，用于衡量模型在整体上预测正确的能力，即：在所有样本中，有多少比例的数据被模型完全预测正确。该指标在类别任务中具有良好的代表性，能够直观反映模型整体的预测能力。其公式定义如下：

$$\text{accuracy} = \frac{1}{n} \sum_{i=1}^n I(y_i = \hat{y}_i) = \frac{TP + TN}{TP + TN + FP + FN} \quad (3-3)$$

其中，在第一部分， n 表示样本数量， $I(\cdot)$ 表示指示函数，若条件成立则为 1，否则为 0， y_i 和 $\hat{y}_i$ 分别代表第 i 个样本的真实类别和预测类别。第二部分是从混淆矩阵角度的定义的准确率公式， TP 表示正类预测为正类的数量， TN 表示负类预测为负类的数量， FP 表示负类预测为正类的数量， FN 表示正类预测为负类的数量。

3.4.3 对比实验

首先，为验证数据集的划分比例对模型性能的影响，评估样本数量变化对模型泛化能力的干扰程度，本章设计了一组基于不同训练集规模的对比实验。具体而言，将原始中药方剂数据集分别按照三种常见比例进行划分，即训练集与测试集比例为 6: 4、7: 3 和 8: 2，并在每一种划分方案下训练 TCM-GCN 模型，记录其在对应测试集上的分类准确率。在实验过程中，除训练集大小外，其余模型参数与训练策略保持一致。每组实验均重复运行 10 次，并取平均值以减少随机性带来的波动。通过对比不同划分比例下模型的分类准确率，可以评估数据量对模型性能的影响。训练集较小可能导致模型欠拟合，影响其对未见样本的泛化能力；训练集较大往往更有助于模型捕捉图中结构信息，从而提升分类准确率。不同样本数量下 TCM-GCN 的预测准确率见表 3.3。

表 3.3 TCM-GCN 在不同的划分样本比例下的预测准确率

Top-k	训练集与测试集比例		
	8: 2	7: 3	6: 4
Top-1	0.5412	0.4667	0.4509
Top-2	0.6819	0.6272	0.6086
Top-3	0.7546	0.7148	0.6958
Top-4	0.8092	0.7738	0.7604
Top-5	0.8454	0.8147	0.8037

表 3.3 的实验结果表明，训练样本数量与预测准确率同步提升。相比于 6:4 和 7:3 的划分方式，8:2 划分在本实验中实现了更优的训练效果和测试性能，这一结果说明，适当增加训练样本的数量有助于模型更充分地学习中药方剂之间的结构关系与药味特征，从而提升模型的预测准确率。

其次，为验证 TCM-GCN 在中药方剂功用分类任务中的有效性，本章选取了多种机器学习模型作为基线方法，与 TCM-GCN 在准确率指标上进行性能对比，这些基线模型均为当前多分类任务中广泛应用的算法，具有良好的代表性。为确保对比实验的公平性，所有模型在相同的数据集划分下进行训练与测试，并统一使用相同的输入特征矩阵与类别标签。为进一步测试模型在多分类任务中的性能，本章还测试了各个模型在 Top-k 分类下的预测准确率，见表 3.4。表 3.4 的实验结果表明，针对本章构建的知识图谱，TCM-GCN 在分类任务中的预测准确率优于其他机

器学习模型,这一结果验证了图神经网络在建模中药方剂之间复杂结构关系上的优势。尽管 TCM-GCN 在 Top-1 分类准确率上表现最优,但其准确率仅能达到 54.12%,仍存在改进空间。值得注意的是,随着 k 值的增大,Top-k 分类的预测准确率呈现出了显著的上升趋势,这一现象表明,TCM-GCN 在输出多个可能类别时,具备较强的语义捕捉能力。

表 3.4 TCM-GCN 与传统机器学习模型的 Top-k 分类预测准确率

Top-k	预测准确率			
	TCM-GCN	RF	SVM	XGBoost
Top-1	0.5412	0.4890	0.5064	0.4908
Top-2	0.6819	0.6619	0.6706	0.6647
Top-3	0.7546	0.7528	0.7597	0.7491
Top-4	0.8092	0.8023	0.8053	0.8055
Top-5	0.8454	0.8410	0.8463	0.8482

3.4.4 结果分析

3.3.3 节实验结果表明,TCM-GCN 模型在准确率评价指标上优于其他传统机器学习方法,基于 GCN 的中药方剂多分类预测模型在整体上表现出较好的分类能力。这一结果说明,TCM-GCN 能够充分利用图结构中蕴含的药物间关联信息,通过图卷积有效建模方剂内部的结构关系与语义特征,从而提升模型的分类效果,因此,TCM-GCN 在处理中药方剂数据时更具优势。此外,Top-k 的分类结果进一步验证了该模型在多分类任务中的实用性,还对中药方剂中常见的“多功用协同”现象具有重要意义。

本章随机选择国标 GB/T31773—2015 中的前三种功效分类类目下的每个类目中的两首中药方剂,进行 Top-3 分类的潜在功效预测,具体结果见表 3.5,表中列出了每首方剂的预测类别、国标中的分类以及功效和主治症状,该结果展示了 TCM-GCN 模型在实际应用中的表现。表 3.5 中的实验结果说明,TCM-GCN 能够对中药方剂进行潜在功效的分类预测,并能准确地预测方剂的实际分类。具体而言,对于表中的每一首中药方剂,其 Top-1 预测分类与国标中的分类结果相符。此外,TCM-GCN 在 Top-3 上的预测分类也符合国标中的功效描述。以五虎汤为例,除了具有解表这个主要功效以外,TCM-GCN 预测其还有祛痰和理气的潜在功效,其在国标中的功效描述为“祛痰止咳”验证了五虎汤的祛痰功效,“宣肺解表”也间接

验证了该方剂有理气的功效。对于麻子仁丸，模型预测其除了具有主要功效泻下外，还有理气和清热的功效，而国标中的功效描述为“行气通便”验证了其理气的功效，“润肠泻热”也验证了其清热的功效。模型预测柴枳半夏汤有祛痰和理气的潜在功效，而国标中的功效描述为“涤痰开结”印证了该方剂有祛痰的潜在功效，“宣肺利气”也验证了其有理气的潜在功效。模型预测冷附汤具有祛痰和清热的潜在功效，而功效描述中的“去痰实，降虚热”恰好验证了其潜在功效。其他中药方剂的潜在功效分类预测结果亦是如此。

表 3.5 TCM-GCN 的 Top-3 预测结果

方名	国标分类	预测分类	功效描述
五虎汤	解表	解表，祛痰，理气	宣肺解表，祛痰止咳
香苏散	解表	解表，理气，和解	疏散风寒，理气和中
麻子仁丸	泻下	泻下，理气，清热	润肠泻热，行气通便
大黄附子汤	泻下	泻下，理血，清热	温里散寒，通便止痛
柴枳半夏汤	和解	和解，祛痰，理气	和解清热，宣肺利气，涤痰开结
冷附汤	和解	和解，祛痰，清热	壮脾胃，去痰实，降虚热，清心气

从实验结果可以看出，TCM-GCN 能够在 Top-1 预测中准确地识别方剂的主要功效类别，在 Top-3 的预测结果中，也能够有效地将方剂归类到各自对应的主要功效类别中，并对其进行潜在功效预测，因此，基于 TCM-GCN 的中药方剂分类预测模型在整体上表现出较好的分类能力。由于中药方剂往往具有功效复合的特性，即对于每一首方剂而言，除本身具有的主要功效外，还具有次要功效，而 TCM-GCN 能够对功效复合的中药方剂进行潜在功效类别预测，这也体现了 TCM-GCN 在中医的临床领域具有较好的应用潜力。

本章的实验有效地验证了 TCM-GCN 在方剂分类任务上的可行性与效果，初步证明了该模型在方剂分类领域的应用潜力，也为后续开展方剂功效预测提供了方法基础与实证支持。然而，由于本文中的应用的国标数据集样本量小、类别多且不平均，TCM-GCN 在 Top-1 上的分类准确率仅能达到 54.12%，尚未达到理想水平。此外，结合中医药理论来看，当前图结构建模方法仍有进一步提升空间。中药方剂的核心原则在于“君臣佐使”的配伍思想，中药方剂的药味组成成分（中药饮片）之间存在主次关系，不同的中药饮片在同一首方剂中的重要性不同。但本章在构建知识图谱时，仅将方剂的前 3 中药味组成（饮片）当成主要成分，这种构图方式未能使模型充分区分中药饮片的重要性，也未能充分体现中药方剂中“君臣佐使”的

语义层级，从而在一定程度上限制了分类精度的提升。未来可以进一步优化模型，以提高其分类的准确度，并扩大其在实际临床和研究中的应用范围。

3.5 本章小结

本章基于药味组成成分的相似性构建了中药方剂知识图谱，并构建了 TCM-GCN。首先，本章介绍了使用自然语言处理国标数据的流程，并展示了其存储样式。其次，详细介绍了基于成分相似性知识图谱的构建方式，并展示了主成分相似的示例。接下来，介绍了本章构建的 TCM-GCN 模型，该模型的构建包含初始特征矩阵的设计和模型分类器的设计。最后，对比了不同训练样本下 TCM-GCN 在 Top-k 分类上的准确率，还对比了 TCM-GCN 与 RF、SVM、XGBoost 三个传统机器学习模型在 Top-k 分类上的准确率。实验结果表明，8:2 的数据集划分比例效果最佳，相较于其他传统机器学习方法，TCM-GCN 在中药方剂分类任务预测准确率最高，但在 Top-1 上的分类准确率仅能达到 54.12%，本章对 TCM-GCN 分类准确率较低的原因进行总结，为后续中药方剂分类的研究提供了依据。在此基础上，下一章将以本章实验为基础，针对现存在的不足提出了相应的改进方法。

第4章 TCM-GAT：基于配伍理论的中药方剂功用分类

4.1 引言

为了完成中药方剂功用的自动化分类任务，本文在前一章收集了国标 GB/T31773—2015 和 GB/T31774—2015 中的方剂信息，基于主成分的相似性构建了中药方剂知识图谱，并验证了该方法的有效性。然而，从中医药理论层面来看，这种构图方式未能充分体现出中药方剂中的配伍理论的语义层级，因此，模型未能准确区分出中药方剂中饮片的主次关系，从而在一定程度上限制了分类精度的提升。为解决上述问题，本章基于国标中 1089 首经典名方组成的数据集构建了“方剂—饮片—药材”中药知识图谱，在中药知识图谱的初始构建中融入“君臣佐使”配伍关系，并将该配伍关系编码为边的嵌入向量，在后续分类任务中动态学习该配伍信息。

本章构建的知识图谱需要模型在训练的过程中动态学习边的权重，从而使模型能自适应地调整不同配伍关系的重要性。然而，TCM-GCN 无法在训练过程中动态学习边权重，主要因为该模型依赖固定的邻接矩阵进行卷积运算，无法根据配伍关系进行差异化建模，所以 TCM-GCN 无法满足要求，为解决上述问题，本章提出了一种图神经网络模型 TCM-GAT 用于中药方剂的功用分类预测。TCM-GAT 的训练过程融合了每首方剂中饮片的君臣配伍关系，因此，TCM-GAT 在方剂类别归属预测时能区分饮片成分的主次角色，提升模型预测的准确性。具体工作如下：首先，针对中药知识图谱，利用国标数据中标注的方剂功用分类结果，训练 TCM-GAT 用于中药方剂功用分类预测；其次，为了提升模型准确性，本文方法将中药君臣配伍关系融入了图注意力网络的模型训练。

由于每首中药方剂由多种药味成分构成，其成分间存在复杂作用，TCM-GAT 难以解释方剂组成成分如何影响方剂的类别划分。为此，本章将可解释图神经网络技术引入到基于中药知识图谱的模型预测任务，旨在理解中药方剂中各饮片成分的作用机制，保证用药透明度与可信度。

4.2 基于配伍理论的中药知识图谱

国标中的数据集经过自然语言处理流程后，所得信息被存储为“中药方剂-中药饮片”和“中药饮片-中药材”的链接关系，见图 3.1。由于组成方剂的饮片存在主次成

分的区别, 本文在中药方剂网^①中提取了方剂中饮片的君臣佐使角色数据, 君臣佐使关系可以视为“中药方剂—中药饮片”关系的属性。以麻黄汤为例, 在国标中提取的方剂及其药味组成数据见表 4.1, 其中, 药味组成(药材)列中的每一种药材与药味组成(饮片)列中的每一种饮片一一对应, 即樟科这种药材经过炮制加工可以成为桂枝这种饮片。

表 4.1 中药方剂数据示例

方名	药味组成: 中药饮片	药味组成: 中药材	类别
麻黄汤	君—麻黄(麻黄)	麻黄	01 解表方
	臣—桂枝(樟科)	樟科	
	佐—苦杏仁(苦杏仁)	苦杏仁	
	使—炙甘草(甘草)	甘草	

本文构建的中药知识图谱如图 4.1 所示。知识图谱中包含三种节点和两种边, 节点分别表示中药方剂、中药饮片和中药材, 边分别表示“中药方剂—中药饮片”和“中药饮片—中药材”的组成关系。每个“中药方剂—中药饮片”对应一种君臣佐使属性, “中药饮片—中药材”无特定属性。其中, 用于模型训练的方剂节点所属类别标签已经标注, 而饮片节点与药材节点作为无标记节点参与图神经网络半监督学习模型的训练。




图 4.1 基于配伍关系的中药知识图谱

^① <https://www.zhongyifangji.com/>

上述方法构建的知识图谱适用于方剂分类任务，是由于方剂药味组成蕴含功效与主治规律，而本研究假设每味方剂所归属的功用分类主要与组成方剂的饮片和中药材相关；另外，以麻黄汤为例，组成该方剂的四味饮片麻黄、桂枝、苦杏仁、炙甘草，其用药剂量的成分主次关系对于方剂的分类至关重要，而且桂枝在麻黄汤中的角色为臣，在桂枝汤中的角色为君，因此构建中药知识图谱需要区分方剂中饮片成分的君臣佐使角色。借助本文的可解释图神经网络，能够直观理解方剂功用分类与哪些饮片紧密相关。

国标 GB/T31774—2015 共收录了 1219 种中药材和 1603 味中药饮片，由于本研究构建的知识图谱是基于中药方剂的组成关系建立的，且存在方剂与饮片之间的一对多关系、饮片与药材之间的一对一关系，以及药材与饮片之间的一对多关系。因此，在所选取的 1089 首经典名方中，实际涉及的中药饮片为 781 味，对应的中药材为 463 种。所以，本章构建的知识图谱数据集包含了 1089 首方剂、781 味饮片和 463 种药材，并在此基础上，进一步整合了药味成分的“君臣佐使”配伍关系。

4.3 TCM-GAT 模型构建

4.3.1 模型整体架构

本文方法采用了图神经网络学习中药知识图谱中的“方剂—饮片”和“饮片—药材”之间的链接关系，并利用方剂节点的功用标记结果，对方剂功用进行分类预测。然而，TCM-GCN 存在如下问题：（i）难以表示“方剂—饮片”链接的君臣佐使类别属性，（ii）模型训练过程中难以在表示饮片君臣佐使属性的同时，动态学习每首方剂中饮片应当分配的权重。为了解决上述问题，本文提出了 TCM-GAT 模型用于中药方剂功用分类预测：（i）TCM-GAT 采用 8 位 embedding 向量表示饮片在每首方剂中的君臣佐使属性，（ii）TCM-GAT 同时利用图注意力网络（GAT）的注意力机制动态学习每首方剂中的各饮片在功用预测中应当分配的权重值。

在训练 TCM-GAT 模型时，本章将随机向量作为中药知识图谱的初始特征，原因如下：（i）在构建的图谱中，该图谱本身蕴含了丰富的信息，图注意力网络可以通过注意力机制在图结构上学习节点的表示，这些随机向量在训练过程中会被优化，逐渐变得有意义；（ii）图注意力网络会根据邻接关系和特征之间的相似性动态调整权重，即使初始特征是随机的，注意力机制也能逐步学习到邻居节点的重要性，从而提取出有用的表示。

TCM-GAT 做方剂节点分类的具体步骤如下：首先，为图谱中的每一个节点随机赋予一个初始的特征向量；将“中药方剂—中药饮片”这类边根据“君臣佐使”关系分别赋予 4 种不同的嵌入向量，将“饮片—药材”这类边赋予相同的嵌入向量，因此，初始边的类别共 5 种。然后，通过训练 TCM-GAT，使每个节点能够学习到融合了图结构信息的特征，在这个过程中边的嵌入向量也不断更新。随着训练的深入，每个节点的特征向量会逐渐收敛，形成低维向量表示。同时，利用分类器的输出结果来确定方剂所属的类别。

假设用 $G=(V,E)$ 表示中药知识图谱，其中 V 和 E 分别表示节点和边的集合， $E=E_1 \cup E_2$ ， E 的子集 E_1 表示边集“方剂—饮片”， E_2 表示边集“饮片—药材”。由于本文的数据集包含了 1089 首方剂、781 味饮片和 463 种药材，因此节点数量 $|V|$ 为 $1089+781+463=2333$ 。本章的初始的特征向量的维度 $d=128$ ，TCM-GAT 的输入包括随机初始化的特征矩阵 $X \in \mathbb{R}^{2333 \times d}$ ；中药知识图谱的邻接矩阵 $A \in \mathbb{R}^{2333 \times 2333}$ 。

TCM-GAT 的输出为方剂的功用分类结果。在方剂分类任务中，图谱中每个方剂节点都会被映射到 c 类（ $c=20$ ，功用方剂分类数）之一。TCM-GAT 的模型参数为 $W=\{W^E, W^I\}$ ，其中 W^E 为 G 中 5 种类型边对应的 embedding 矩阵 $W^E \in \mathbb{R}^{5 \times 8}$ ，5 为君臣佐使加上“饮片—药材”5 种边的类别，8 为预定义的 embedding 向量维度（TCM-GAT 与 GAT 的准确率相差 2.64%，即君臣佐使数据对于模型准确率提升为 2.64%，然而，本文测试发现该 embedding 维度参数在 8、16、32 等时对于模型性能影响小于 0.05%，因此选择了性能最高的 8 为 embedding 向量维度）； W^I 为第 l 层图注意力网络进行线性变换时的参数。若模型输出为 Y ，则 TCM-GAT 也可以表示为公式：

$$Y = \text{softmax}(\text{GAT}(X, A, W)) \quad (4-1)$$

其中，GAT 为多层图注意力网络。

4.3.2 融合多头注意力机制的图注意力层

多头注意力机制 (Multi-Head Attention) 是图注意力网络模型中的核心设计之一，其赋予了模型并行化融合信息的能力，使模型能同时捕捉输入序列或图节点之间多种层面的关系。其中，每个注意力头可以学习不同的特征表示或邻居之间的不同关系。例如，在中药知识图谱中，不同注意力头可以分别关注方剂饮片药材之间的组成关系和方剂饮片之间的“君臣佐使”配伍关系等。因此，将 TCM-GAT 设置成多头注意力机制结构来整合信息。TCM-GAT 的特征提取图如图 4.2 所示，该模型采用 8 个注意力头。




图 4.2 TCM-GAT 模型中的特征维度变化图

在 TCM-GAT 中，输入特征维度为 2333×128 。在第一层图注意力网络中，8 个注意力头将输入特征映射为 8 个 2333×16 维的节点表示，然后，将 8 个注意力头的输出在特征维度上进行拼接（concat），从而得到第一层的节点特征表示，其维度为 2333×128 。在第二层图注意力网络中，8 个注意力头将第一层的输出特征映射成 8 个 2333×20 维的特征表示，然后，第二层对 8 个注意力头的输出结果进行平均（mean）聚合，从而得到最终的节点特征表示，其维度为 2333×20 。

设 TCM-GAT 使用的网络层数为 $l (l \geq 2)$ 层，则第 l 层 TCM-GAT 的输入特征矩阵为 $X \in \mathbb{R}^{2333 \times d_l}$ ，输出特征矩阵为 $X' \in \mathbb{R}^{2333 \times d_{l+1}}$ 。图注意力网络首先对每个节点 v_i 在 X 中对应的特征向量 x_i 进行线性变换 $W^l x_i$ ， $W^l \in \mathbb{R}^{d_{l+1} \times d_l}$ 是 GAT 的参数矩阵；再计算边 (v_i, v_j) 的注意力系数 α_{ij} ，见公式（4-2），在计算 α_{ij} 的过程中，将图结构中边的初始 embedding 向量与节点特征一起拼接。在公式（4-2）中， N_i 为 v_i 的邻居节点， $\alpha \in \mathbb{R}^{2d_{l+1}+8}$ 为注意力权重向量，是一个可学习参数， $W_{ij} \in \mathbb{R}^{1 \times 8}$ 是边 (v_i, v_j) 在 W^E 中对应的君臣佐使或者“饮片—药材”关系的 embedding 向量，LeakyReLU 为激活函数， T 为转置操作， $\parallel$ 为拼接操作。

$$\alpha_{ij} = \frac{\exp(\text{LeakyReLU}(a^T [W^l x_i \parallel W^l x_j \parallel W_{ij}]))}{\sum_{k \in N_i} \exp(\text{LeakyReLU}(a^T [W^l x_i \parallel W^l x_k \parallel W_{ij}]))} \quad (4-2)$$

在实际训练中，本文选取的网络层数为 2，初始特征的维度为 128，那么在 TCM-GAT 中，初始输入的特征矩阵 $X \in \mathbb{R}^{2333 \times 128}$ ，输出的特征矩阵 $X' \in \mathbb{R}^{2333 \times 20}$ 。在第一层中， $W^1 \in \mathbb{R}^{128 \times 128}$ ，则计算 α_{ij} 的过程中得到的拼接矩阵 $[W^1 x_i \parallel W^1 x_j \parallel W_{ij}] \in \mathbb{R}^{2 \times 128 + 8}$ ；在第二层中， $W^2 \in \mathbb{R}^{128 \times 20}$ ，则计算 α_{ij} 的过程中得到的拼接矩阵 $[W^2 x_i \parallel W^2 x_j \parallel W_{ij}] \in \mathbb{R}^{2 \times 20 + 8}$ 。

边的可学习参数 W_{ij} 属于非显式更新范式，即边特征在前向传播过程中仅作为计算注意力权重的条件，并不随层级变化而产生新的表示，其参数值通过反向传播机制进行更新，公式如下：

$$W_{ij} \rightarrow W_{ij} - \eta \frac{\delta L}{\delta W_{ij}} \quad (4-3)$$

其中， η 是学习率， L 表示损失函数。

设每层并行计算 K 个注意力头，每个头生成一组注意力系数矩阵，中间层（前 $l-1$ 层）通过拼接多头输出并应用激活函数 ReLU 更新节点特征，见公式（4-4）；末层（第 l 层）对多头结果取平均，见公式（4-5）。在公式（4-4）中， x_i^l 为节点 v_i 的输出特征， $\alpha_{ij}^{l,k}$ 和 $W^{l,k}$ 分别为第 k 个头的注意力系数和权重矩阵。

$$x_i^l = \text{ReLU} \left(\sum_{j \in N_i} \alpha_{ij}^{l,k} W^{l,k} x_j^{l-1} \right) \quad (4-4)$$

$$x_i^l = \text{ReLU} \left(\frac{1}{K} \sum_{k=1}^K \sum_{j \in N_i} \alpha_{ij}^{l,k} W^{l,k} x_j^{l-1} \right) \quad (4-5)$$

最终，TCM-GAT 结合 softmax 和交叉熵损失函数完成分类预测任务，通过不断优化模型参数，使模型能够有效学习中药方剂图谱中节点及边的语义信息。

TCM-GAT 完整的架构图见图 4.3，该图以节点 v_1 为例展示了使用 8 头注意力机制的图神经网络做节点分类的过程。在图 4.3 中，输入的图结构是本文构建的知识图谱，其中， v_1 表示中药方剂， v_2 和 v_3 表示中药饮片， v_4 表示中药材，其初始特征向量为 $\{x_1, x_2, x_3, x_4\}$ ，该图中对应的“君臣佐使”初始嵌入向量（边向量）为 $\{e_{12}, e_{13}, e_{24}, e_{34}\}$ ，将每个节点的特征向量和边的 embedding 同时输入到模型。首先，对每个节点的特征向量做线性变换，再将线性变换后的特征输入到 Attention（注意力机制）中，以得到注意力系数如 $\alpha_{12}^{(1,1)}$ 等，在每一层 TCM-GAT 中，只有在每个注意力头中的 Attention 模块计算中会用到边的向量，Attention 模块的计算见图 4.4；接下来，将线性变换后的特征向量和注意力系数做加权聚合，其计算公式见（2-10），最后得到更新后的节点特征，其中，模型的第一层通过将 8 个注意力头得到的节点特征做 Concat（拼接），以更新节点特征，得到 $x^{(1)}$ ，第二层通过将 8 个注意力头的得到的节点特征做 Mean（平均），以更新节点特征，得到 $x^{(2)}$ ；最后，将 $x^{(2)}$ 输入到 softmax 分类器，得到每个节点的概率分布。




图 4.3 TCM-GAT 架构图

在图 4.4 中，展示的是图 4.3 中第一个注意力头的 Attention，在 Attention 模块，首先，将线性变换后的节点 v_1 与 v_2 的特征以及初始边的 embedding 向量做 concat，再将其输入到注意力打分函数，见公式（2-8），以得到注意力分数 $e_{12}^{(1,1)}$ 和 $e_{13}^{(1,1)}$ ，再将注意力系数经过 softmax 函数，见公式（2-10），以得到 v_1 与 v_2 间的注意力系数 $\alpha_{12}^{(1,1)}$ 和 v_1 与 v_3 间的注意力系数 $\alpha_{13}^{(1,1)}$ 。




图 4.4 TCM-GAT 的 Attention 模块

在训练过程中，模型不断调整注意力权重与节点特征表示，以最小化预测标签与真实标签之间的差异，从而提升分类准确率。TCM-GAT 不仅挖掘了中药方剂和饮片之间的配伍关系，还增强了模型对多类别任务的适应性。设经过 softmax 归一化后可得到其属于每个类别的概率 $\{p_i, p_i, \dots, p_c\}$ ，则概率中的最大值即为模型的单一预测结果，除此外，本章也对预测概率进行 Top-k 类别的提取，以得到每首中药方剂的多类别预测结果，对于中医领域的临床诊断具有重要意义。

4.4 TCM-GAT 实验设置与结果分析

4.4.1 参数设置

本章按 8:2 划分训练集和测试集。TCM-GAT 采用两层网络结构，具体参数设置如下：注意力头为 8，维隐藏层维度为 128，学习率为 0.01，dropout 为 0.4，优化器为 Adam，权重衰减（weight_decay）为 $5e-6$ ，添加自环（add_self_loops）为 True，batch 为 512。训练上限 3000 轮，设定的中止机制：若测试集的损失值在连续 100 轮训练后未再下降，则终止训练过程。

本章选用 RF、SVM、XGBoost、K 近邻（K-Nearest Neighbors, KNN）和决策树（Decision Tree, DT）等 5 种传统机器学习方法和 GraphSAGE（Graph Sample And aggreGatE）这种深度学习模型作为对比模型，各模型的参数配置如下：

- （1）RF：学习率设为 0.1，criterion 设为 gini，n_estimators 设为 500，max_depth 设为 5，min_samples_leaf 设为 1，bootstrap 设为 True；
- （2）SVM：kernel 设为 linear，probability 设成为 True；
- （3）XGBoost：学习率设为 0.1，n_estimators 设为 1000，max_depth 设为 6，subsample 设为 0.8，colsample_bytree 设为 0.8，objective 设为 multi:softmax，probability 设为 True；

(4) KNN: 邻居数量 (`n_neighbors`) 设为 11, 权重方式 (`weights`) 设为 `distance`

(5) DT: `criterion` 设为 `gini`, `max_depth` 设为 5; `min_samples_leaf` 设为 1;

(6) GraphSAGE: 网络层数为 2, 学习率设为 0.01, 隐藏层维度设为 256, 激活函数为 ReLU, Dropout 为 0.5, 分类器为 LogSoftmax, 优化器为 Adam, `weight_decay` 设为 $5e-4$ 。

4.4.2 评估指标

为评估模型在功用分类任务中的性能表现, 常选用多种分类评价指标进行量化分析。在多分类任务中, 通常使用微平均 (Micro-average) 或宏平均 (Macro-average), 微平均适用于样本量大、类别均衡的数据; 宏平均适用于类别不平衡的数据。考虑到本任务属于多类别分类问题, 且存在类别分布不均衡的情况。因此, 选用宏平均作为评估指标。

1) 精准率

精准率 (Precision) 的定义是在所有被模型预测为“正例”的样本中, 真正的“正例”所占的比例, 用于衡量模型做出正预测时的可信度。宏平均精准率公式如下:

$$\text{macro precision} = \frac{1}{c} \sum_{i=1}^c \frac{TP_i}{TP_i + FP_i} \quad (4-6)$$

其中, c 表示类别数, TP_i 是真正例, 表示被预测为第 i 类且实际也是第 i 类的样本数, FP_i 是假正例, 表示被预测为第 i 类但实际不是第 i 类的样本数。

2) 召回率

召回率 (Recall) 的定义是在所有真实的“正例”样本中, 被模型正确预测出来的比例。宏平均召回率公式如下:

$$\text{macro recall} = \frac{1}{c} \sum_{i=1}^c \frac{TP_i}{TP_i + FN_i} \quad (4-7)$$

其中, FN 是假负例, 表示真实标签是正类, 但模型错误地预测为负类的样本数量。

3) F1 值

F1 值是精准率与召回率的调和平均数, 其核心定义是模型在精准率和召回率上综合表现能力的量化分数, 特别适用于类别不平衡的数据集。调和平均数的特点是, 只有当两个值都较高时, F1 值才高, 若其中一个值很低, 则会显著拉低最终结果。因此, F1 值可解决单一指标的片面性问题。本文选用宏平均 F1 作为评估指标, 宏平均

F1 先对每个类别分别计算 F1 值，再取平均，其公式如下：

$$\text{macro F1} = \frac{1}{c} \sum_{i=1}^c F1_i \quad (4-8)$$

4.4.3 对比与消融实验

首先,为了验证 TCM-GAT 的性能,本章对比了 TCM-GAT 与 SVM、RF、XGBoost、KNN、DT 等 5 种传统机器学习方法和 GraphSAGE 在方剂分类任务中的性能,除此外,还将 TCM-GAT 与 GAT 的性能进行了对比,其中, GAT 和 GraphSAGE 模型的训练采用了图 4.1 所示的知识图谱,但受模型结构的限制,未包含其中的“君臣佐使”配伍关系。测试指标包括: Accuracy、Precision、Recall 和 F1,在测试过程中,将 Precision、Recall 和 F1 设置成宏平均。在对比实验中,所有对比方法使用相同特征矩阵,并调参至最优。实验结果见表 4.2。

表 4.2 TCM-GAT 与其他模型的性能对比(%)

算法	Accuracy	Precision	Precision	F1
TCM-GAT	68.42	72.17	58.54	62.16
GAT	65.78	66.13	51.89	54.09
SVM	51.92	43.20	44.10	42.08
RF	45.19	27.03	25.24	24.16
XGBoost	51.92	37.91	37.01	36.37
KNN	37.50	21.10	21.78	18.25
DT	28.85	12.20	14.30	11.97
GraphSAGE	59.62	46.58	44.54	42.76

表 4.2 的实验结果表明, TCM-GAT 在准确率、精准率、召回率和 F1 值等 4 个指标上的性能均优于其他模型,这也验证了该模型在多类别的中药方剂功用分类任务上具有优势,并且在多分类任务中表现最佳。相较于 GAT 在准确率上 65.78%的结果而言, TCM-GAT 在准确率这个指标上高了 2.64%,在其他 Precision、Recall 和 F1 等测试指标上均优于 GAT。这一提升表明, GAT 虽有动态注意力机制,但未能引入中药知识图谱中边的特征(即“君臣佐使”配伍关系),导致其在处理该图谱时存在一定的局限性,而 TCM-GAT 通过边嵌入机制将“君臣佐使”配伍关系纳入到注意力系数的计算过程,使得模型在建模中药方剂图谱结构时,能够更有效地利用“君臣佐使”配

伍信息所蕴含的语义关系，从而提升模型在中药方剂功用分类方面的能力。

其次，为了进一步验证 TCM-GAT 的有效性，本章对比了 TCM-GAT 与 GAT、GCN 在中药方剂功用分类任务中的 Top-k 分类准确率，其中，GAT 和 GCN 模型的训练采用了图 4.1 所示的知识图谱，但受模型结构的限制，未包含其中的“君臣佐使”配伍关系。通过对比不同模型在 Top-k 指标下的预测准确率，可以更全面地评估 TCM-GAT 在多类别任务中的表现，还能证明该模型有较高的实用价值。不同模型在 Top-k 分类上的预测准确率见表 4.3。

表 4.3 三个模型在 Top-k 分类上的预测准确率(%)

算法	Top-1	Top-2	Top-3	Top-4	Top-5
GCN	45.19	56.73	67.31	77.88	81.37
GAT	65.78	76.92	83.65	89.42	93.27
TCM-GAT	68.42	81.73	86.54	91.35	95.19

表 4.3 对比了 TCM-GAT 与 GAT、GCN 在 Top-5 分类上的准确率。实验表明，TCM-GAT 和 GAT 从 Top-1 到 Top-5 的分类准确率均高于 GCN，即使用 GAT 做中药方剂多分类的效果显著优于 GCN，而 TCM-GAT 从 Top-1 到 Top-5 的分类准确率又高于 GAT，所以，在 TCM-GAT 和 GAT 中，使用 TCM-GAT 在中药方剂多分类的任务中更具有优势。因此，当 k 取值相同时，TCM-GAT 在预测准确率上的性能优于 GAT，而 GAT 又优于 GCN。实验还表明，随着 k 的增大，Top-k 分类的预测准确率显著提升，这也能够说明本章的研究可以为中药方剂的潜在功效分类预测提供支持。

接下来，本章通过对层数（表 4.4）和注意力头数（表 4.5）进行消融实验，以分析不同参数配置对模型性能的影响，从而选定最优的模型参数。同时，将 TCM-GAT 模型与经典 GAT 模型在多分类任务上的准确率进行对比实验，进一步验证本文所构建的 TCM-GAT 在多分类任务中的分类效果优于 GAT，体现引入中药配伍关系建模后对模型性能提升的有效性。

表 4.4 网络层数变化对模型准确率的影响(%)

网络层数/层	2	3	4	5
GAT	65.78	62.50	25.00	19.23
TCM-GAT	68.42	64.42	29.81	19.23

表 4.5 注意力头数变化对模型准确率的影响(%)

注意力头数/个	1	2	3	4	5	6	7	8	9	10
GAT	60.58	65.38	65.78	65.38	63.46	64.42	61.54	65.78	63.46	59.62
TCM-GAT	59.62	66.35	68.27	66.35	65.38	64.42	65.38	68.42	64.42	64.42


表 4.4 的实验结果显示，当网络层数为 2 时，TCM-GAT 和 GAT 两种模型均取得最高准确率，分别为 68.42%和 65.78%，但随着网络层数的增加，模型的准确率呈现下降趋势，这是因为模型出现了过平滑现象，即随着网络层数的增加，节点特征逐渐变得相似甚至相同，从而导致模型区分不同节点的能力下降；而 2 层网络结构的模型在保证信息充分聚合的同时，有效避免了过平滑现象。在网络层数设置为 2 的条件下，本文又做了注意力头数的消融实验，表 4.5 的实验结果显示，两个模型在只使用 1 个注意力头的情况下，准确率分别为 60.58%和 59.62%，为所有设置中最低。这表明，注意力头数量过少时，模型难以捕捉节点与其邻居之间更丰富的关系，导致模型表达能力受限，从而影响分类性能。尽管增加注意力头的数量通常可以提升模型的表示能力，但并非越多越好。实验中也观察到，当注意力头数增加至 9 或 10 时，两个模型的性能反而有所下降，这可能是由于过多的注意力头引入了冗余信息或噪声，导致模型出现过拟合现象。当注意力头数设置为 8 时，TCM-GAT 在中药方剂功用分类任务中取得了最高的准确率 68.42%。两表的实验结果说明，TCM-GAT 在（网络层数为 2，注意力头数为 8）的参数配置下模型的性能最优。同时，结果也显示，即使随着注意力头和网络层数的变化，TCM-GAT 的预测准确率也高于 GAT，该消融实验的结果进一步验证了 TCM-GAT 的有效性。

本章还对比了 TCM-GAT 与机器学习模型和深度学习模型的复杂度，实验结果见表 4.6。从表 4.6 中可以看出，在模型规模方面，TCM-GAT 与 GAT 拥有相同的参数量，但模型大小略小，且在 GPU 显存占用上，TCM-GAT 仅需 31.72MB，显著低于 GAT 的 51.10 MB，也低于 GCN 与 GraphSAGE，而传统机器学习模型不占用 GPU 内存。在推理效率方面，TCM-GAT 的吞吐量达到 653.96 样本/s，明显优于 GAT 的 620.82 样本/s，这表明 TCM-GAT 可以有效降低计算开销。TCM-GAT 的吞吐量也优于 SVM、RF 和 KNN，仅低于 GraphSAGE、DT 和 XGBoost。整体来看，TCM-GAT 在显存占用和推理速度方面均优于 GAT，实现了更高的资源利用效率，并且相较于传统机器学习模型也展现出明显优势。

表 4.6 TCM-GAT 与其他模型复杂度的对比

模模型 评价指标	参数量 (个)	模型大小 (MB)	吞吐量 (样本/s)	GPU 占用内存 (MB)	推理时间 (ms)
TCM-GAT	137020	0.5200	653.96	31.72	1.5292
GAT	137020	0.5227	620.82	51.10	1.6108
GCN	17076	0.0651	657.65	48.38	1.5206
GraphSAGE	272660	1.0401	1722.47	50.92	1.0401
SVM	0	0.0000	380.12	0.00	2.6308
RF	7480	0.0285	246.35	0.00	4.0592
XGBoost	5882	0.0224	676.75	0.00	1.4779
KNN	0	0.0000	97.49	0.00	10.2579
DT	33	0.0001	6675.11	0.00	0.1498

此外，本文还绘制了 TCM-GAT 和其他对比模型的 ROC (Receiver Operating Characteristic) 曲线和 PR (Precision-Recall) 曲线，见图 4.5。



(b) 图 4.5 ROC 曲线与 PR 曲线

(a) ROC 曲线

(b) PR 曲线

从图 4.5 可以看出，在 ROC 曲线上，TCM-GAT 的 ROC-AUC 达到 0.959，远高于其他 GNN 模型，也明显优于传统机器学习模型。需要注意的是，在高度不均衡的多分类任务中，ROC-AUC 对类别比例不敏感，往往会呈现较高的数值。然而，即便在这种情况下，TCM-GAT 仍优于其他对比模型，说明其整体判别能力更强。相比之下，

PR 曲线更能真实地反映模型在少数类上的识别能力。TCM-GAT 的 PR-AP 达到 0.8733，超过所有对比模型。综合 ROC 与 PR 两个指标，TCM-GAT 在整体分类性能和少数类识别能力上均表现最优，体现了 TCM-GAT 处理基于配伍理论构建的知识图谱的能力。

4.4.4 结果分析

为验证 TCM-GAT 在中药方剂功效分类任务中的有效性，本章从国标 GB/T31773—2015 中选择前三个功效分类类目，即解表类、泻下类和和解类，并随机选取每个类目中的两首中药方剂（与第 3.4.3 节选取的方剂一致），进行分类的功效预测，并将预测结果与真实标签进行对比，实验结果见表 4.7，该表直观的展示了 TCM-GAT 模型在中药方剂功效分类任务中的实际表现。表 4.7 中每一味中药方剂的类别预测均与国标数据集中实际的类别一致，该结果展示了 TCM-GAT 模型在多个功效类别的预测上均表现出良好的能力，也为后续对于该预测结果的解释分析提供了基础。

表 4.7 TCM-GAT 的预测结果

方名	国标分类	预测分类
五虎汤	解表	解表
香苏散	解表	解表
麻子仁丸	泻下	泻下
大黄附子汤	泻下	泻下
柴枳半夏汤	和解	和解
冷附汤	和解	和解

4.5 TCM-GAT 可解释性验证与实验分析

4.5.1 模型的后验解释

本章以 GNNShap 为例介绍模型的解释过程。GNNShap（见图 4.6）在解释过程中每次选择一个方剂节点 v ，研究 v 的某一邻域内邻居（在中药知识图谱中，该邻域包含组成方剂节点 v 的饮片和中药材）对分类结果的影响。GNNShap 解释过程如下：（1）首先，将初始特征 x 和图结构 A 输入到 GNNShap 中，GNNShap 对图剪枝，移除与 v 无关的边，并生成更小的修剪子图（包含节点 v 及组成它的饮片和药材节点）；（2）

然后，通过随机采样少量代表性修剪子图替代遍历所有可能组合，以大幅降低计算开销，该阶段会生成掩码矩阵 M 和权重向量 W ，利用矩阵 M 得到样本，即修剪子图的多个子图，把这些样本输入到训练好的 TCM-GAT 模型中，对每个样本产生一个目标节点预测值 y_v ；（3）最后，利用上述 M 、 W 和 y_v 计算每条边的 Shapley 值，即对于方剂节点 v 分类的贡献。




图 4.6 GNNShap 解释框架

在该解释框架中，利用 TCM-GAT 计算节点 v 的修剪子图中所有边的贡献，修剪子图中有 6 条有向边（6 个玩家），掩码矩阵代表对所有可能的边的组合（即合作博弈论中玩家联盟）的采样，权重向量代表每个样本的权重，每个采样子图用于计算节点分类预测，再基于预测结果计算边的 Shapley 值。

4.5.2 实验环境与参数配置

本实验是基于 PyTorch 完成的，所采用的实验平台环境具体配置见表 4.8。

表 4.8 实验环境配置

名称	标准
操作系统	Ubuntu22.04 LTS
内存	24GB
CPU	Intel(R) Core(TM) i9-12900K
GPU	NVIDIA GeForce RTX 3090
CUDA	12.1

各解释方法的实验参数配置如下：

(1) Saliency (SA) [72]：计算节点特征的梯度，并将梯度之和视为节点解释，因此无参数；

(2) GNNExplainer：利用互信息学习重要边和特征。学习率为 0.01，epoch 为 200；

(3) PGExplainer：利用互信息训练神经网络，无需单独训练即可提供解释。学习率为 0.05，epoch 为 200；

(4) PGM-Explainer：该方法通过概率图模型学习节点重要性，使用默认设置；

(5) GraphSVX：采样策略为 SmarterSeparate，最大联盟规模设为 5，采样联盟数量为 10000，特征值为 Expectation（期望）；

(6) GNNShap：batch size 为 512，采样策略为 SmarterSeparate，最大联盟规模设为 5，采样联盟数量为 10000，特征值为 Expectation。

4.5.3 评估指标

为了测试后验可解释方法的性能，本章选择使用 Fidelity-和 Fidelity+作为评估指标，Fidelity±可以针对真实类别或预测类别进行计算。由于可解释图神经网络关注的是模型在实际预测过程中的行为，因此在评估中选择使用模型预测的类别作为解释目标。Fidelity-和 Fidelity+指标通过观察移除边后模型预测结果的变化来评估解释方法的准确性。Fidelity-专注于移除不重要的边，我们希望移除被认为不重要的边后，模型预测结果保持不受显著影响（即性能下降最小）。因此，Fidelity-值越小表示可解释方法越好。Fidelity+专注于移除重要的边，我们希望移除被认为重要的边后，模型预测结果会受到显著干扰（即性能明显下降）。因此，Fidelity+值越大表示可解释方法越好。Fidelity-和 Fidelity+公式如下：

$$\text{fidelity-} = \frac{1}{n} \sum_{i=1}^n \left| f(G_C)_{y_i} - f(G_S)_{y_i} \right| \quad (4-9)$$

$$\text{fidelity+} = \frac{1}{n} \sum_{i=1}^n \left| f(G_C)_{y_i} - f(G_{C \setminus S})_{y_i} \right| \quad (4-10)$$

在公式 (4-9) 中， $f(G_C)_{y_i}$ 表示在图 G_C 上，模型对第 i 个样本预测的得分（对预测类别 y_i 的置信度）， $f(G_S)_{y_i}$ 表示在解释子图 G_S 上，模型对同一类别的预测得分。两者之差表示去掉图中部分信息后，模型对原预测类别的信心下降了数值。差值越小，说明解释子图越能代表原图的决策依据，解释效果越好。在公式 (4-10) 中， $G_{C \setminus S}$ 表示从图 G_C 中移除解释子图 G_S 后的图， $f(G_{C \setminus S})_{y_i}$ 表示在移除子图后的图上，模型对原预测类

别的得分,该值与 $f(G_C)_{y_i}$ 的差值越大,说明被移除的子图对预测影响越大,即越重要。

4.5.4 对比实验

本文采用 SA、GNNExplainer、GNNShap、PGExplainer、PGMExplainer 和 GraphSVX 等六种后验可解释方法来解析方剂分类决策,并以 Fidelity±来评估其性能。这些方法涵盖了基于特征遮蔽(如 SA)、边权重扰动(如 GNNExplainer、PGExplainer)、图结构建模(如 PGMExplainer)以及 Shapley 值近似(如 GNNShap、GraphSVX)等多种主流解释方法,能够从不同角度揭示模型在中药方剂分类任务中的决策依据。在实验中,针对每种解释方法生成的子图或特征子集,使用 Fidelity+和 Fidelity-两个指标计算其在原模型上的预测一致性,以衡量解释结果对模型决策的忠实程度。Fidelity±指标通过观察移除边后模型预测结果的变化来评估解释方法的准确性,本实验通过调节边移除比例(稀疏度)与关键边数量(重要度),测试各解释方法的 Fidelity±指标,实验测得的 Fidelity-数据见表 4.9。

表 4.9 Fidelity-在不同稀疏水平下的得分

Spar sity	SA	GNN- Explainer	PG-Explainer	PGM- Explainer	GraphSVX	GNNShap
10	0.007±0.000	0.009±0.000	0.011±0.000	0.007±0.000	0.005±0.000	0.009±0.000
20	0.015±0.000	0.024±0.001	0.024±0.000	0.014±0.001	0.012±0.000	0.019±0.000
30	0.023±0.000	0.038±0.001	0.038±0.000	0.020±0.001	0.019±0.000	0.027±0.000
40	0.031±0.000	0.050±0.001	0.054±0.000	0.026±0.000	0.027±0.000	0.035±0.001
50	0.045±0.000	0.069±0.002	0.087±0.000	0.035±0.000	0.036±0.000	0.047±0.001
60	0.052±0.000	0.077±0.002	0.090±0.000	0.040±0.001	0.037±0.000	0.052±0.001
70	0.061±0.000	0.088±0.001	0.094±0.000	0.047±0.001	0.043±0.000	0.059±0.001
80	0.078±0.000	0.102±0.001	0.101±0.000	0.063±0.002	0.059±0.000	0.072±0.001

表 4.9 结果显示,在移除不同边的条件下,GraphSVX 在 Fidelity-指标上的表现均优于其他方法,即 GraphSVX 更能精准判别方剂和饮片关联关系的重要程度。在 Fidelity-评估指标下,随着移除的不重要边比例(sparsity)的增加,各种方法的 Fidelity-得分逐渐增加,但增加的数值量逐渐变小,GraphSVX 的 Fidelity-得分最小,即表现最优,PGMExplainer 紧随其后,GNNShap 也展现出一定的鲁棒性,GNNExplainer 和

PGExplainer 的 Fidelity-得分相对较高,说明二者在识别不重要边时可能存在误判或冗余保留,从而影响了解释结果的可信度。随着 sparsity 值的增加, Fidelity-得分逐渐增加,该实验结果也能表明移除的解释子图中不重要边的数量越多,模型性能下降越多,从而证明了该解释子图的重要性。

实验测得的 Fidelity+数据见表 4.10,该结果显示, GraphSVX 在 Fidelity+指标上的表现均优于其他方法。在初始阶段 (Top-k=5 时),各解释方法的 Fidelity+得分差距较大,对模型决策的关键边识别能力存在明显差异, GraphSVX 方法能够更好地捕捉到对预测结果影响最大的信息。然而,随着移除的关键边数量的增加, Fidelity+得分的差距逐渐缩小,但增加到一定程度 (如 Top-k=35 时) 后其值将不会再改变,并且各解释方法的 Fidelity+得分近似相等。该实验结果还能表明,通过增加移除的关键边数量会削弱模型的结构信息,会导致预测结果不再稳定,因此,各解释方法之间的差异性也不再显著。

表 4.10 Fidelity+在不同 Top-k 水平下的得分

Top-k	SA	GNN- Explainer	PG- Explainer	PGM- Explainer	GraphSVX	GNNShap
5	0.069±0.000	0.051±0.001	0.049±0.000	0.076±0.001	0.111±0.000	0.073±0.001
10	0.106±0.000	0.092±0.001	0.105±0.000	0.113±0.001	0.143±0.000	0.107±0.001
15	0.129±0.000	0.122±0.001	0.137±0.000	0.134±0.001	0.147±0.000	0.129±0.001
20	0.139±0.000	0.140±0.000	0.145±0.000	0.143±0.000	0.147±0.000	0.140±0.001
25	0.145±0.000	0.147±0.000	0.148±0.000	0.147±0.000	0.149±0.000	0.146±0.000
30	0.148±0.000	0.149±0.000	0.149±0.000	0.149±0.000	0.149±0.000	0.148±0.000
35	0.148±0.000	0.150±0.000	0.150±0.000	0.149±0.000	0.150±0.000	0.149±0.000
40	0.149±0.000	0.150±0.000	0.150±0.000	0.149±0.000	0.150±0.000	0.149±0.000
45	0.149±0.000	0.150±0.000	0.150±0.000	0.149±0.000	0.150±0.000	0.149±0.000
50	0.149±0.000	0.150±0.000	0.150±0.000	0.149±0.000	0.150±0.000	0.150±0.000

为更直观地展示各方法在 Fidelity±指标下的表现,本文对其结果进行了可视化,如图 4.7 所示。




图 4.7 Fidelity±得分的变化

(a) Fidelity-得分的变化 (b) Fidelity+得分的变化

为了进一步验证各方法的综合性能，本章还对各解释方法在时间效率方面进行评估。表 4.11 展示了可解释方法的训练时间和节点的总解释时间。其中，本实验测试了 GNNShap 方法在 10000、25000 和 50000 样本数量下所需的时间。

表 4.11 可解释方法训练时间和总解释时间(秒)

可解释方法	训练时间	总解释时间
SA	0.00±0.00	0.19±0.03
GNNExplainer	0.00±0.00	42.71±0.73
PGExplainer	38.44±0.70	0.16±0.00
PGMEExplainer	0.00±0.00	244.50±0.98
GraphSVX	0.00±0.00	1 462.95±1.88
GNNShap 10k	0.00±0.00	6.88±0.02
GNNShap 25k	0.00±0.00	13.36±1.31
GNNShap 50k	0.00±0.00	24.79±0.88

表 4.11 结果显示，从训练时间来看，除 PGExplainer 方法外，其他方法的训练可以瞬间完成；从总解释时间来看，SA 和 PGExplainer 总解释时间非常短，GraphSVX 的解释时间最长，高达 1462.95 秒，计算开销较大。尽管 GraphSVX 在 Fidelity± 指标下的表现优于其他方法，但其总解释时间远远高于其他方法，相比之下，GNNShap 在采样数量与 GraphSVX 相同（样本数量为 10000）的情况下，总解释时间为 6.88 秒，即使采样数量增加的情况下，也能较快地完成解释，因此，该方法在效率与解释质量之间取得了较好的平衡。尽管基于 Shapley 的方法通常被认为速度较慢，但 GNNShap

仍保持更快的性能，这是因为 GNNShap 中的并行采样与剪枝策略使时间大幅度缩短。

此外，本章还测试了 6 种可解释图神经网络方法的复杂度，结果见表 4.12。

表 4.12 可解释图神经网络方法的复杂度对比表

评估指标 模型	参数量 (个)	向前传播次数 (次)	采样次数 (次)	吞吐量 (样本/秒)	占用 GPU 内存 (MB)
SA	0	2	0	94.74	45.99
GNNExplainer	0	51	0	3.05	45.43
PGExplainer	0	2	0	241.44	41.73
PGMExplainer	0	52	50	0.34	117.96
GraphSVX	0	51	10	3.66	45.32
GNNShap	0	28	200	64.23	59.54

从表 4.12 可以看出，不同可解释图神经网络方法在计算开销和资源占用方面存在显著差异。具体而言，SA 与 PGExplainer 属于轻量级方法，仅需 2 次前向传播而无需采样操作，在所有方法中 PGExplainer 的吞吐量最高，达到 241.44 样本/秒，显著优于其他方法，因此，PGExplainer 在效率上具有明显优势。相比之下，GNNExplainer、GraphSVX 和 PGMExplainer 均需要 51-52 次前向传播，其中 PGMExplainer 还包含 50 次采样，导致吞吐量降至 0.34 样本/秒，并且 GPU 内存占用最高，是所有方法中计算成本最大的解释器。GNNShap 的采样次数最多，达到 200 次，但其吞吐量仍达到 64.23 样本/秒，显著高于 GNNExplainer、GraphSVX 和 PGMExplainer 方法。上述实验结果也能表明，GNNShap 在采样次数较多的情况下，仍能维持较高的运行效率。

4.6 结果分析

上述实验证明了 GraphSVX 在 Fidelity-和 Fidelity+两个指标下的性能优于其他方法，但结合时间评价指标和 Fidelity±整体来看，GNNShap 综合效果也比较好的。因此，本节将分别展示 GNNShap 和 GraphSVX 的解释结果，并以九味羌活汤（中药方剂）为例，展示经过两种可解释方法得到的药味组成（中药饮片）对九味羌活汤分类的贡献值和解释子图，GNNShap 的解释结果见图 4.8。在图 4.8 中，图(a)是使用 GNNShap 方法做解释后得到的方剂中各饮片的贡献，各饮片的贡献以 Shapley 值量化（结果保留两位小数），其中，蓝色表示负值，红色表示正值。图(b)是使用图(a)的解释结果绘制的九味羌活汤的解释子图，本章中的解释子图由 $|\text{Shapley 值}| \geq 0.01$ 的边组成，

在图（b）中，红 / 蓝色分别表示正 / 负贡献，颜色深度反映贡献强度。





图 4.8 GNNShap 的解释结果

(a) 节点贡献的可视化图 (b) 解释子图

GraphSVX 的解释结果见图 4.9，该图中颜色的表示与图 4.8 一致。





图 4.9 GraphSVX 的解释结果

(a) 节点贡献的可视化图 (b) 解释子图

解释结果显示，GNNShap 与 GraphSVX 对九味羌活汤的解释结论基本一致：羌活、防风、麸炒苍术、细辛在推动九味羌活汤被归为解表类上起促进作用，且防风、细辛的贡献相近，地黄、黄芩片起抑制作用，而白芷因用量小（佐药）整体贡献微弱。二者差异体现在对白芷的判定：GNNShap 基于局部贡献度量，认为白芷与羌活、防风起协同作用，判定其弱促进；GraphSVX 侧重全局特征独立性，认为白芷的清热属性（与黄芩、地黄起拮抗作用）与九味羌活汤被分为解表类关联较弱，判定其弱抑制。白芷的双向作用源于其化学成分的协同（与羌活 / 防风共促解表）与拮抗（与黄芩 /

地黄寒热冲突)潜力,而微量使用使其贡献被主药效应覆盖。

表 4.13 对比了 GNNShap、GraphSVX 与大模型对 GB/T31773—2015 前 5 首方剂的解释结果。对九味羌活汤, GNNShap 和大模型两类方法结果如下:羌活、防风、麸炒苍术、细辛、白芷在推动方剂归为辛温解表类别上的促进作用,黄芩片、地黄、甘草起抑制作用,验证了中药方剂的君臣配伍理念。对于川芎(佐药)的贡献,大模型依据臣助君原则判为弱促进,而 GNNShap 量化结果趋近中性。此差异源于解释方法的区别:大模型依赖中医理论的先验框架,强调整体性;而 GNNShap 基于数据分析得出的量化局部贡献,对于辅助药味成分的贡献更为敏感。通过对表 4.13 中其他方剂分析表明, GNNShap 不仅与 GraphSVX 在主药作用解读上较为一致,还与传统大模型在主药作用解读上较为一致,差异集中于辅助药:辅助药作用弱、化学成分复杂,由于 GNNShap 的局部与全局视角,会导致其与主药交互后贡献弱化,显示出弱促进或抑制作用,故量化结果趋近中性。相较于传统大模型主要依赖定性推断各药味的作用, GNNShap 等方法能够精准解析方剂中各成分贡献,其子结构归因可视化优于大模型黑盒推断,契合中医理法方药动态机制分析需求。明确方剂内各成分的作用机制,能够为临床配药提供可靠依据。例如,若模型显示某辅助药的贡献趋近中性,可结合中医理论进一步验证其滋阴防燥的辅助配药意图,而非简单视为无效成分。

表 4.13 与大模型的解释结果对比

方名	预测作用	GNNShap	GraphSVX	大模型
麻黄汤	促进	麻黄>桂枝>炙甘草	麻黄>桂枝>炙甘草	麻黄>桂枝
	抑制	苦杏仁	苦杏仁	苦杏仁>炙甘草
桂枝汤	促进	桂枝>生姜>大枣>白芍>炙甘草	桂枝>生姜>白芍>大枣>炙甘草	桂枝>生姜>白芍>大枣
	抑制	—	—	炙甘草
九味羌活汤	促进	羌活>防风>细辛>白芷>麸炒苍术	羌活>防风~细辛>麸炒苍术	羌活>防风>麸炒苍术>细辛>川芎>白芷
	抑制	黄芩片>地黄>甘草>川芎	黄芩片>地黄>白芷>甘草>川芎	黄芩>地黄>甘草
香苏散	促进	紫苏叶>醋香附>炙甘草	紫苏叶>醋香附>炙甘草	紫苏叶>醋香附>陈皮
	抑制	陈皮	陈皮	炙甘草
小青龙汤	促进	麻黄>桂枝>白芍>细辛	麻黄>桂枝>白芍>炙甘草	麻黄>桂枝>细辛
	抑制	五味子>姜半夏>干姜>炙甘草	五味子>姜半夏>干姜>细辛	五味子>干姜>姜半夏>炙甘草>白芍

4.7 本章小结

本章提出了中药方剂分类预测模型 TCM-GAT，并结合可解释图神经网络方法对分类结果进行解释。首先，介绍了中药知识图谱的构建思路。其次，介绍了 TCM-GAT 的构建思路以及融合“君臣佐使”配伍关系的训练。接下来，将 TCM-GAT 与其他模型的性能在多个评估指标上进行对比分析，实验表明，TCM-GAT 通过建模中药知识图谱复杂关联提升了多分类精度。最后，将分类结果使用多种后验解释方法进行解释，还评估各种方法的性能，并分析了饮片成分的配伍对方剂功用分类的影响，为解析方剂与优化用药配比提供新工具。此外，本章不仅选择具有代表性的解释方法将其结果进行可视化分析，还将本章的解释结果与经典大模型的解释结果做了对比分析，并结合中医领域知识进一步验证了该解释的有效性。

第5章 总结与展望

5.1 全文研究工作总结

本文首先介绍了中药方剂分类的研究背景，回顾了该领域的研究方法及其局限性，针对目前人工方式完成中药方剂的功效分类面临着数据量大、成本高等问题，构建了 TCM-GCN 以实现中药方剂自动化分类。由于 TCM-GCN 在实现中药方剂自动化分类时，未能充分区分中药方剂的药味组成成分（饮片）主次成分，即 TCM-GCN 的训练未融合方剂的配伍信息而导致模型训练效果未达到预期。在此基础上，本文提取了各饮片的君臣佐使配伍关系，并将其做成边的初始 **embedding** 向量，使其在模型的训练中学习。因此，为了在模型的训练中可以融入君臣佐使配伍关系，本文构建了 TCM-GAT，并引入了可解释图神经网络方法，对 TCM-GAT 的分类结果进行解释，具体内容如下：

（1）为了帮助数十万首中药方剂数据实现自动化分类，本文构建了 TCM-GCN，该模型的构建主要分为三步：首先，基于自然语言处理后的数据集，利用中药方剂成分的相似性构建了中药方剂知识图谱；其次，基于该图谱构建了包括中药饮片和中药材信息的特征矩阵；最后，设计了节点分类器，并输出预测结果。实验结果表明，TCM-GCN 可以有效实现中药方剂功效的自动化分类，相较于其他传统机器学习模型，该模型具有显著优势，但存在提升空间，即模型在训练的过程中未融合方剂的配伍信息，从而导致模型分类效果一般。

（2）为解决 TCM-GCN 在实现中药方剂功效的自动化分类时未能融合方剂的配伍关系信息的问题，本文构建了 TCM-GAT，TCM-GAT 的训练过程融合了每首方剂中饮片的君臣配伍关系，因此 TCM-GAT 在方剂类别归属预测时能区分饮片成分的主次角色，从而提升模型预测的准确性。该模型的构建主要分为三步：首先，基于国标数据集，构建了基于配伍理论的中药方剂知识图谱；其次，将图谱中方剂与饮片之间对应的君臣佐使关系映射成 **embedding** 矩阵，其中每种角色（君、臣、佐、使）对应一个独立的向量表示，并在 TCM-GAT 的计算中，将该向量与线性变换后的节点特征向量进 **concat**，共同参与注意力系数的计算。最后，设计了节点分类器，并输出预测结果。实验结果表明，TCM-GAT 实现中药方剂功效的自动化分类的性能显著优于 TCM-GCN，该结果证明了实现中药方剂分类时融入方剂的君臣佐使配伍信息的有效性。

(3) 为解决图神经网络在做中药方剂分类时决策信息不透明的问题, 本文引入了诸多后验可解释图神经网络方法, 各方法从不同角度揭示了模型在中药方剂分类任务中的决策依据, 并选择解释性能较好的模型, 将其解释结果进行可视化分析。实验结果显示, 可解释图神经网络能够有效揭示方剂分类任务中药味组成成分的贡献度, 从而能准确衡量方剂的饮片成分与和其功用之间的关联性, 本文还通过与主流大模型解释结果的对比分析, 进一步验证了解释可信度。

5.2 未来研究工作展望

本文在实现中药方剂分类的过程中取得了一定的成果, 但仍存在不足, 需要在以后的科研工作中进一步研究与改善, 主要包括以下几方面:

(1) 受限于国标中现有中药方剂数据的获取难度和标注成本, 本研究所使用的数据规模仍然有限, 部分功效类别样本数量偏少, 会对 TCM-GAT 模型的泛化能力产生一定影响。未来工作可以通过引入更大规模、更高质量的中药方剂数据集, 或结合多来源数据进行扩充, 以进一步提升 TCM-GAT 模型的稳定性与鲁棒性。

(2) 本文主要从“君臣佐使”配伍关系的角度对中药方剂结构进行建模, 尚未充分考虑药味、归经等更为丰富的中医药知识信息。未来可以将更多中医领域知识以节点属性或边属性的形式引入图模型中, 并进一步探索多视角建模方法, 以构建更全面的中药方剂知识图谱, 从而提升方剂分类的效果。

参考文献

- [1] 李春晓, 李丹, 凌霄, 等. 中药临床药师教学药历内容与记录规范的探讨[J]. 中国药房, 2022, 33(21): 2671-2675.
- [2] Scarselli F, Gori M, Tsoi A C, et al. The graph neural network model[J]. IEEE Transactions on Neural Networks, 2008, 20(1): 61-80.
- [3] 郭文博, 龙伟, 蒋林华, 等. 基于图神经网络的药物相互作用预测方法研究综述[J]. 现代计算机, 2024, 30(20): 36-40.
- [4] Zhang X M, Liang L, Liu L, et al. Graph neural networks and their current applications in bioinformatics[J]. Frontiers in Genetics, 2021, 12: 690049.
- [5] 中国中医科学院中医药信息研究所. 中国方剂数据库[EB/OL]. (2023-07-23) [2025-08-23]. https://www.ncmi.cn/phda/dataDetails.do?id=CSTR%3AA0006.11.A0007.201906.000223&utm_source=copilot.com.
- [6] 陈昭, 曹燕凤, 何帅兵, 等. 基于药性理论的清热药功效分类模型研究[J]. 中华中医药杂志, 2017, 32(05): 2107-2111.
- [7] 郭永坤, 章新友, 刘莉萍, 等. 基于神经网络的中药方剂功效预测系统研究[J]. 时珍国医国药, 2019, 30(02): 493-495.
- [8] Gao W Q, Cheng N, Xin G J, et al. TCM2Vec: a detached feature extraction deep learning approach of traditional Chinese medicine for formula efficacy prediction[J]. Multimedia Tools and Applications, 2023, 82(17): 26987-27004.
- [9] Bai T, Guan H T, Wang S, et al. Traditional Chinese medicine entity relation extraction based on CNN with segment attention[J]. Neural Computing and Applications, 2022, 34(4): 2739-2748.
- [10] 金博文, 王豫骞, 樊薛津, 等. 基于Preferential Attachment-VIKOR算法的阿尔茨海默病中药处方“方证”关系预测与处方综合评价[J]. 中草药, 2025, 56(22): 8273-8282.
- [11] Zhou J, Cui G Q, Hu S D, et al. Graph neural networks: A review of methods and applications[J]. AI open, 2020, 1: 57-81.
- [12] 黄海新, 杜亭亭. 基于图神经网络的推荐算法综述[J]. 通信与信息技术, 2023, (03): 65-69.
- [13] Yao L, Zhang Y, Wei B G, et al. A topic modeling approach for traditional Chinese medicine prescriptions[J]. IEEE Transactions on Knowledge and Data Engineering, 2018, 30(6): 1007-1021.
- [14] Wang X Y, Zhang Y, Wang X L, et al. A knowledge graph enhanced topic modeling approach for herb recommendation[C]. International Conference on Database Systems for Advanced Applications. Cham: Springer International Publishing, 2019: 709-724.
- [15] Jin Y Y, Zhang W, He X N, et al. Syndrome-aware herb recommendation with multi-graph convolution network[C]. 2020 IEEE 36th International Conference on Data Engineering (ICDE). California: IEEE, 2020: 145-156.
- [16] Kipf T N. Semi-supervised classification with graph convolutional networks[J]. arXiv (2016-09-09) [2025-09-08]. <https://doi.org/10.48550/arXiv.1609.02907>.
- [17] Zhao W, Lu W K, Li Z Y, et al. TCM herbal prescription recommendation model based on multi-graph convolutional network[J]. Journal of Ethnopharmacology, 2022, 297: 115109.

- [18] Yang Y, Rao Y L, Yu M H, et al. Multi-layer information fusion based on graph convolutional network for knowledge-driven herb recommendation[J]. *Neural Networks*, 2022, 146: 1-10.
- [19] 黄辛迪, 李亚春, 黄群富. 基于词向量和神经网络的方剂分类模型研究[J]. *信息与电脑(理论版)*, 2022, 34(17): 63-66.
- [20] 刘丽蓉, 詹秀菊. 基于BP神经网络和支持向量机的荨麻疹证候分类探讨[J]. *广州中医药大学学报*, 2020, 37(03): 573-577.
- [21] 阮开霞, 李冰, 冉宇, 等. 多种机器学习与反向传播神经网络模型在中医补益类方剂分类中的对比研究[J]. *中医药导报*, 2025, 31(07): 232-237.
- [22] Kang Y F, Wu M X, Gao Y L, et al. Deep learning-based classification of traditional Chinese medicine: a novel approach[J]. *Quantitative Imaging in Medicine and Surgery*, 2025, 15(8): 7483-7496.
- [23] Kanawong R, Obafemi-Ajayi T, Ma T, et al. Automated tongue feature extraction for ZHENG classification in traditional Chinese medicine[J]. *Evidence-Based Complementary and Alternative Medicine*, 2012, 2012(1): 912852.
- [24] Kanawong R, Obafemi-Ajayi T, Yu J, et al. ZHENG classification in Traditional Chinese Medicine based on modified specular-free tongue images[C]. 2012 IEEE International Conference on Bioinformatics and Biomedicine Workshops. New Jersey: IEEE, 2012: 288-294.
- [25] Moorhouse T P, Zhou Z M, Ye Y C, et al. What is "TCM"? A conservation-relevant taxonomy of traditional Chinese medicine[J]. *Global Ecology and Conservation*, 2021, 32: e01905.
- [26] 王传庆, 李阳阳, 费超群, 等. 知识图谱平台综述[J]. *计算机应用研究*, 2022, 39(11): 3201-3210.
- [27] Fabian M, Gjergji K, Gerhard W. Yago: A core of semantic knowledge unifying wordnet and wikipedia[C]. 16th International World Wide Web Conference. Banff: WWW, 2007: 697-706.
- [28] Miller G A. WordNet: a lexical database for English[J]. *Communications of the ACM*, 1995, 38(11): 39-41.
- [29] Huang Z H, Xu W, Yu K. Bidirectional LSTM-CRF models for sequence tagging[J/OL]. *arXiv* (2015-08-09) [2025-09-21]. <https://doi.org/10.48550/arXiv.1508.01991>.
- [30] 卢克治. 基于中医古籍的知识图谱构建与应用[D]. 北京: 北京交通大学, 2020.
- [31] 杜伯涵. 基于知识图谱的中医智能导诊系统[D]. 北京: 北京邮电大学, 2021.
- [32] 刘禹琪. 中医名方知识图谱构建与链路预测模型的研究及应用[D]. 长春: 东北师范大学, 2021.
- [33] 李兵, 裘俭, 张华敏. 中医药领域本体研究概述[J]. *中国中医药杂志*, 2010, 17(03): 100-101+106.
- [34] Kipf T N, Welling M. Variational graph auto-encoders[J/OL]. *arXiv* (2016-11-21) [2025-11-21]. <https://doi.org/10.48550/arXiv.1611.07308>.
- [35] Lan S Y, Ma Y T, Huang W K, et al. Dstagnn: Dynamic spatial-temporal aware graph neural network for traffic flow forecasting[C]. *International Conference on Machine Learning*. Massachusetts: PMLR, 2022: 11906-11917.
- [36] You J X, Liu B W, Ying R, et al. Graph convolutional policy network for goal-directed molecular graph generation[J]. *Advances in Neural Information Processing Systems*, 201

- 8, 31: 6412-6422.
- [37] Bang S J, Jhee J H, Shin H. Polypharmacy side-effect prediction with enhanced interpretability based on graph feature attention network[J]. *Bioinformatics*, 2021, 37(18): 2955-2962.
- [38] Ying R, He R N, Chen K F, et al. Graph convolutional neural networks for web-scale recommender systems[C]. *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. New York: ACM, 2018: 974-983.
- [39] Schlichtkrull M, Kipf T N, Bloem P, et al. Modeling relational data with graph convolutional networks[C]. *European Semantic Web Conference*. Cham: Springer International Publishing, 2018: 593-607.
- [40] Li G H, Muller M, Thabet A, et al. DeepGCNs: Can GCNs go as deep as CNNs?[C]. *Proceedings of the IEEE/CVF International Conference on Computer Vision*. New Jersey: IEEE, 2019: 9267-9276.
- [41] Liu Y, Wang L M, Liu M, et al. Spherical message passing for 3d molecular graphs[EB/OL]. (2022-02-29) [2025-12-06]. https://openreview.net/forum?id=givsRXsOt9r&utm_source=copilot.com.
- [42] Hamilton W, Ying Z, Leskovec J. Inductive representation learning on large graphs[J]. *Advances in Neural Information Processing Systems*, 2017, 30: 1024-1034.
- [43] Veličković P, Cucurull G, Casanova A, et al. Graph attention networks[J/OL]. *arXiv* (2017-10-30) [2025-08-09]. <https://doi.org/10.48550/arXiv.1710.10903>.
- [44] Gasteiger J, Bojchevski A, Günnemann S. Predict then propagate: Graph neural networks meet personalized pagerank[J/OL]. *arXiv* (2018-10-14) [2025-12-02]. <https://doi.org/10.48550/arXiv.1810.05997>.
- [45] Xu K, Hu W, Leskovec J, et al. How powerful are graph neural networks?[J]. *arXiv* (2018-10-01) [2025-12-02]. <https://doi.org/10.48550/arXiv.1810.00826>.
- [46] Teng S H, Fu A, Lu W K, et al. TCM syndrome classification using graph convolutional network[J]. *European Journal of Integrative Medicine*, 2023, 62: 102288.
- [47] Wang H M, Xu M, Guo Z T, et al. DTI-BGCGCN: A novel bipartite graph-based cluster graph convolutional network for drug-target interaction prediction in modern and traditional chinese medicine[J]. *Computational Biology and Chemistry*, 2025, 117: 108410.
- [48] Samanta A, Mitra S, Banerjee B, et al. Cluster-GAT: Mixing Convolutional and Self-Attended Feature Maps Using Graph Attention Networks for Cervical Cell Classification[C]. *International Conference on Frontiers in Computing and Systems*. Singapore: Springer Nature Singapore, 2023: 409-418.
- [49] Yang S Z, Zhang L, Zhang X F. FastGAT: Simple and Efficient Graph Attention Neural Network with Global-Aware Adaptive Computational Node Attention[C]. *ICASSP 2024-2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. New Jersey: IEEE, 2024: 5555-5559.
- [50] 黄锦泉, 左兆灿. 基于图注意力网络的在线医生推荐研究 [J]. *情报探索*, 2023, (11): 113-119.
- [51] Xiong Z P, Wang D Y, Liu X H, et al. Pushing the boundaries of molecular representation for drug discovery with the graph attention mechanism[J]. *Journal of Medicinal Chemistry*, 2019, 63(16): 8749-8760.
- [52] Yuan Y N, Zhang Y H, Meng X B, et al. EDC-DTI: an end-to-end deep collaborative learning model based on multiple information for drug-target interactions prediction[J]. *Jo*

- urnal of Molecular Graphics and Modelling, 2023, 122: 108498.
- [53] Yang X Y, Ding C S. SMRGAT: A traditional Chinese herb recommendation model based on a multi-graph residual attention network and semantic knowledge fusion[J]. Journal of Ethnopharmacology, 2023, 315: 116693.
- [54] Wang Y S, Wan Y L, Hu H P. Multi-task meta-attention network for traditional Chinese medicine diagnostic recommendation[J]. Frontiers in Public Health, 2025, 13: 1549679.
- [55] Duvenaud D K, Maclaurin D, Iparraguirre J, et al. Convolutional networks on graphs for learning molecular fingerprints[J]. Advances in Neural Information Processing Systems, 2015, 28: 2224-2232.
- [56] Ying Z, Bourgeois D, You J, et al. Gnnexplainer: Generating explanations for graph neural networks[J]. Advances in Neural Information Processing Systems, 2019, 32: 9240-9251.
- [57] Luo D S, Cheng W, Xu D K, et al. Parameterized explainer for graph neural network[J]. Advances in Neural Information Processing Systems, 2020, 33: 19620-19631.
- [58] Rao J H, Zheng S J, Lu Y T, et al. Quantitative evaluation of explainable graph neural networks for molecular property prediction[J]. Patterns, 2022, 3(12): 100628-100628.
- [59] Gui S, Yuan H, Wang J, et al. Flowx: Towards explainable graph neural networks via message flows[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 46(7): 4567-4578.
- [60] Duval A, Malliaros F D. Graphsvx: Shapley value explanations for graph neural networks[C]. Joint European Conference on Machine Learning and Knowledge Discovery in Databases. Cham: Springer International Publishing, 2021: 302-318.
- [61] Perotti A, Bajardi P, Bonchi F, et al. Explaining identity-aware graph classifiers through the language of motifs[C]. 2023 International Joint Conference on Neural Networks(IJCNN). Queensland: IEEE, 2023: 1-8.
- [62] Zhang S C, Liu Y Z, Shah N, et al. Gstarx: Explaining graph neural networks with structure-aware cooperative games[J]. Advances in Neural Information Processing Systems, 2022, 35: 19810-19823.
- [63] Li H, Han Z B, Sun Y, et al. CGMega: explainable graph neural network framework with attention mechanisms for cancer gene module dissection[J]. Nature Communications, 2024, 15(1): 5997.
- [64] GNNShap: Fast and accurate GNN explanations using shapley values[J/OL]. arXiv (2024-05-13) [2025-08-20]. <https://doi.org/10.1145/3589334.3645>.
- [65] He K M, Zhang X Y, Ren S Q, et al. Deep residual learning for image recognition[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Nevada: IEEE, 2016: 770-778.
- [66] Elfving S, Uchibe E, Doya K. Sigmoid-weighted linear units for neural network function approximation in reinforcement learning[J]. Neural Networks, 2018, 107: 3-11.
- [67] Misra D. Mish: A self regularized non-monotonic activation function[J/OL]. arXiv (2019-08-23) [2025-12-30]. <https://doi.org/10.48550/arXiv.1908.08681>.
- [68] Agarap A F. Deep learning using rectified linear units (relu)[J]. arXiv (2018-03-22) [2025-12-30]. <https://doi.org/10.48550/arXiv.1803.08375>.
- [69] Vu M, Thai M T. Pgm-explainer: Probabilistic graphical model explanations for graph neural networks[J]. Advances in Neural Information Processing Systems, 2020, 33: 12225-12235.

- [70] Lundberg S M, Lee S I. A unified approach to interpreting model predictions[J]. Advances in Neural Information Processing Systems, 2017, 30: 4765-4774.
- [71] Kinga D, Ba J. Adam: A method for stochastic optimization[J/OL]. arXiv (2014-12-22) [2025-08-18]. <https://doi.org/10.48550/arXiv.1412.6980>.
- [72] Simonyan K, Vedaldi A, Zisserman A. Deep inside convolutional networks: Visualising image classification models and saliency maps[J]. arXiv (2013-12-20) [2025-12-17]. <https://doi.org/10.48550/arXiv.1312.6034>.

附录 攻读硕士学位期间取得的成果

1) 发表论文:

(1) XXX, XXX, XX, XX 等. TCM-GAT:基于知识图谱的中药方剂分类与解释.长春理工大学学报.(已录用, 第一作者)

2) 参加的科研项目:

(1) 吉林省教育厅科学研究项目《基于大规模语义网络的药物相互作用预测方法研究》, 项目号: JJKH20240947KJ

致谢

时光荏苒，转瞬即逝，在长春理工大学的求学生涯已接近尾声，回首初入校园的场景，依旧清晰如昨，在这三年时光里，我不断成长，也收获了许多宝贵的经验。在本论文的完成过程中，我得到了许多人的帮助，在此谨向他们表达最由衷的谢意。

言传身教，惠我良多。感谢我的导师 XXX，XXX 在整个研究生阶段始终给予我悉心的指导与关怀。在学术上，XXX 循循善诱、授人以渔，从课题选题、研究思路的梳理到论文的撰写，每个环节都给予了我深刻的指导。当我研究遇到瓶颈时，XXX 总能耐心地为我在答疑解惑，帮助我重新梳理思路、重拾信心。在生活中，XXX 同样会给予我鼓励与支持。XXX 严谨的学风和乐观豁达的生活态度深深影响了我，使我不仅在学业上精进，更在为人处世上获益匪浅。

并肩前行，幸得挚友。感谢课题组的各位同学，在实验设计、数据处理和论文讨论的各个环节都能给予我宝贵的建议，让我在每一次的交流与讨论中都能深受启发。感谢你们在我遇到困难时毫不犹豫地施以援手。在这段求学的岁月里，与你们相伴让我感到无比的温暖和快乐。我还要诚挚感谢吉林省物联网应用技术实验室的所有成员，感谢你们提供的良好的科研环境与丰富的资源，让我能在积极、融洽的氛围中专注学习与研究。

寸草春晖，难报深恩。感谢我的家人，你们一直以来的理解、支持与鼓励，是我最坚强的后盾，正是你们无条件的陪伴与信任，让我在面对压力与挑战时从容不迫，勇往直前。

三载砥砺前行路，点滴皆成心底光。行文至此，感谢自己一直以来的坚持与努力，感谢自己在迷惘时仍选择前行，在压力中仍保持热爱。愿未来之路，继续保持热爱，奔赴新的山海！